

Maestría en Inteligencia Artificial

Alumnas:

Ariadna Garmendia - María Carina Roldán

ANÁLISIS DE SERIES DE TIEMPO II

**Análisis de series temporales de
temperatura de superficie en bosques de
pino y estepa en la Patagonia argentina**

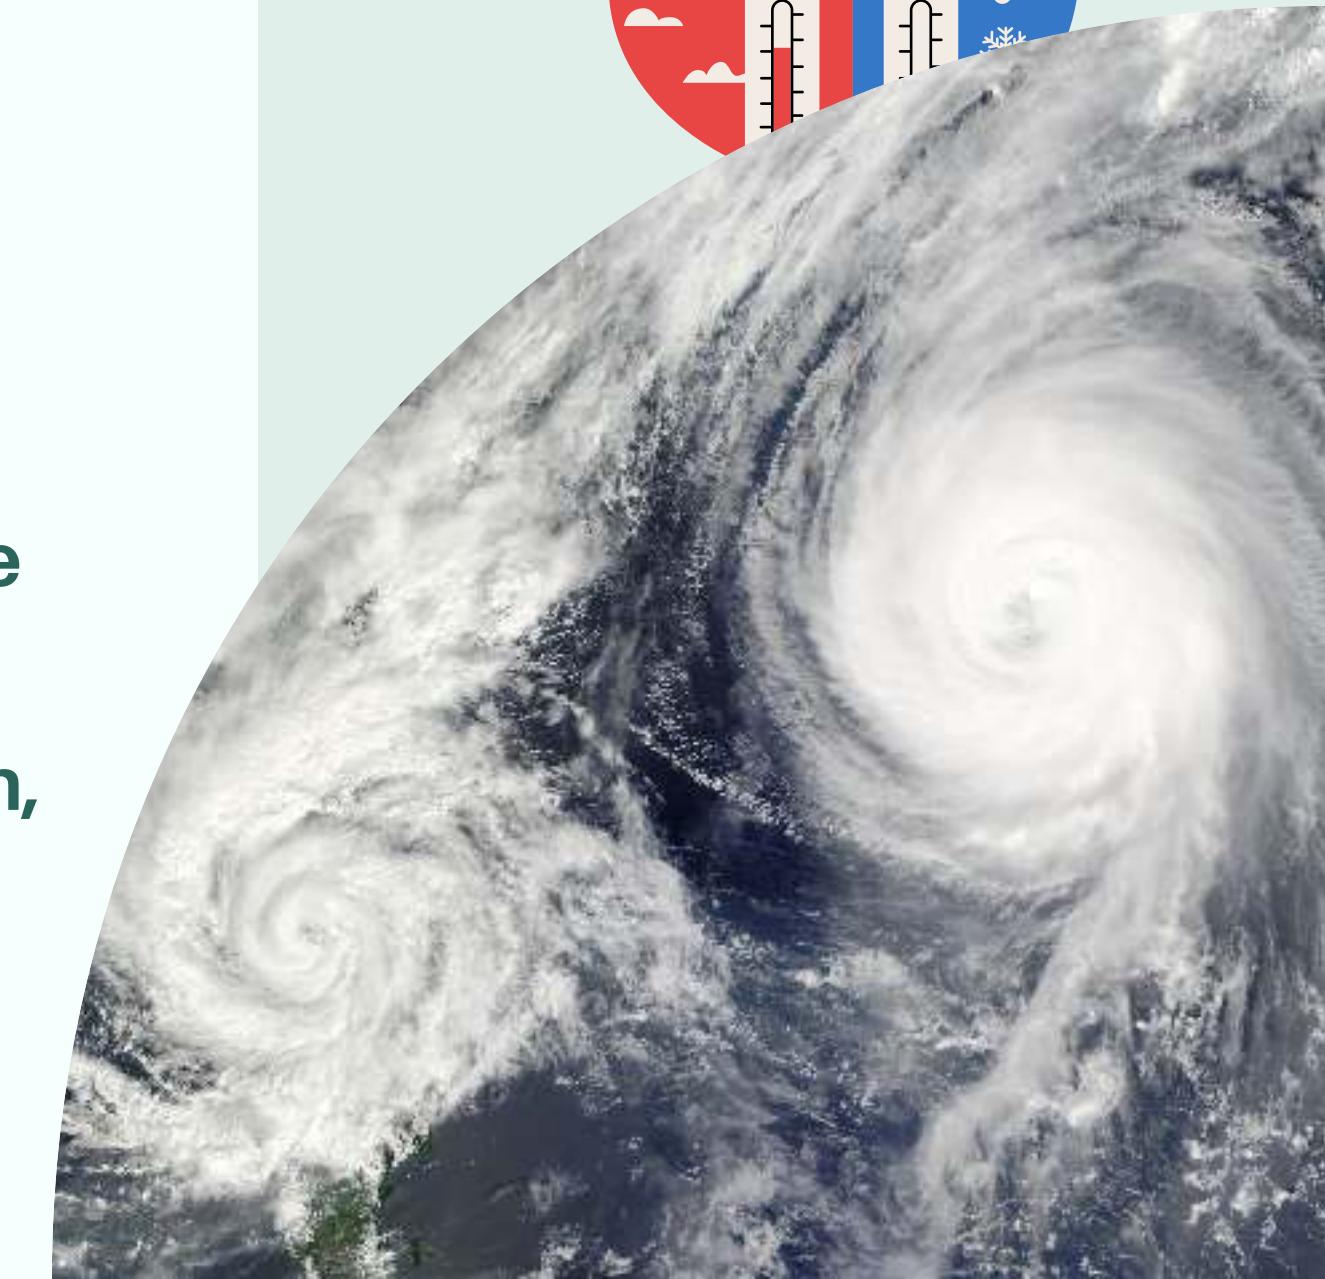
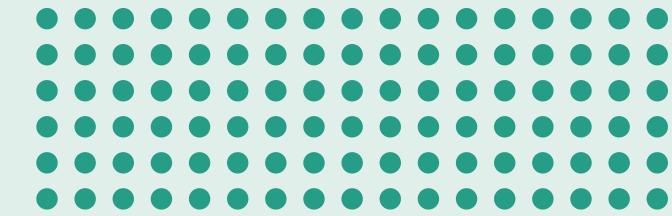


Introducción

Este trabajo surge como una continuación del trabajo final realizado para la materia Análisis de Series de Tiempo I.

Objetivo

Analizar la diferencia térmica entre coberturas de bosques de pino y estepas para poder detectar procesos de recuperación, sequías, deforestación, entre otras.



Introducción

LST (Land Surface Temperature)

- Se estima a partir de la radiación infrarroja emitida por suelo y vegetación.
- Es un indicador de procesos ecológicos y climáticos.

Variable de interés

Diferencia térmica entre coberturas de bosques de pino y estepas (delta) que se calcula a partir de las LST individuales:

$$\Delta LST = LST \text{ estepa} - LST \text{ pino}$$



Trabajo realizado en AST I

Los datos

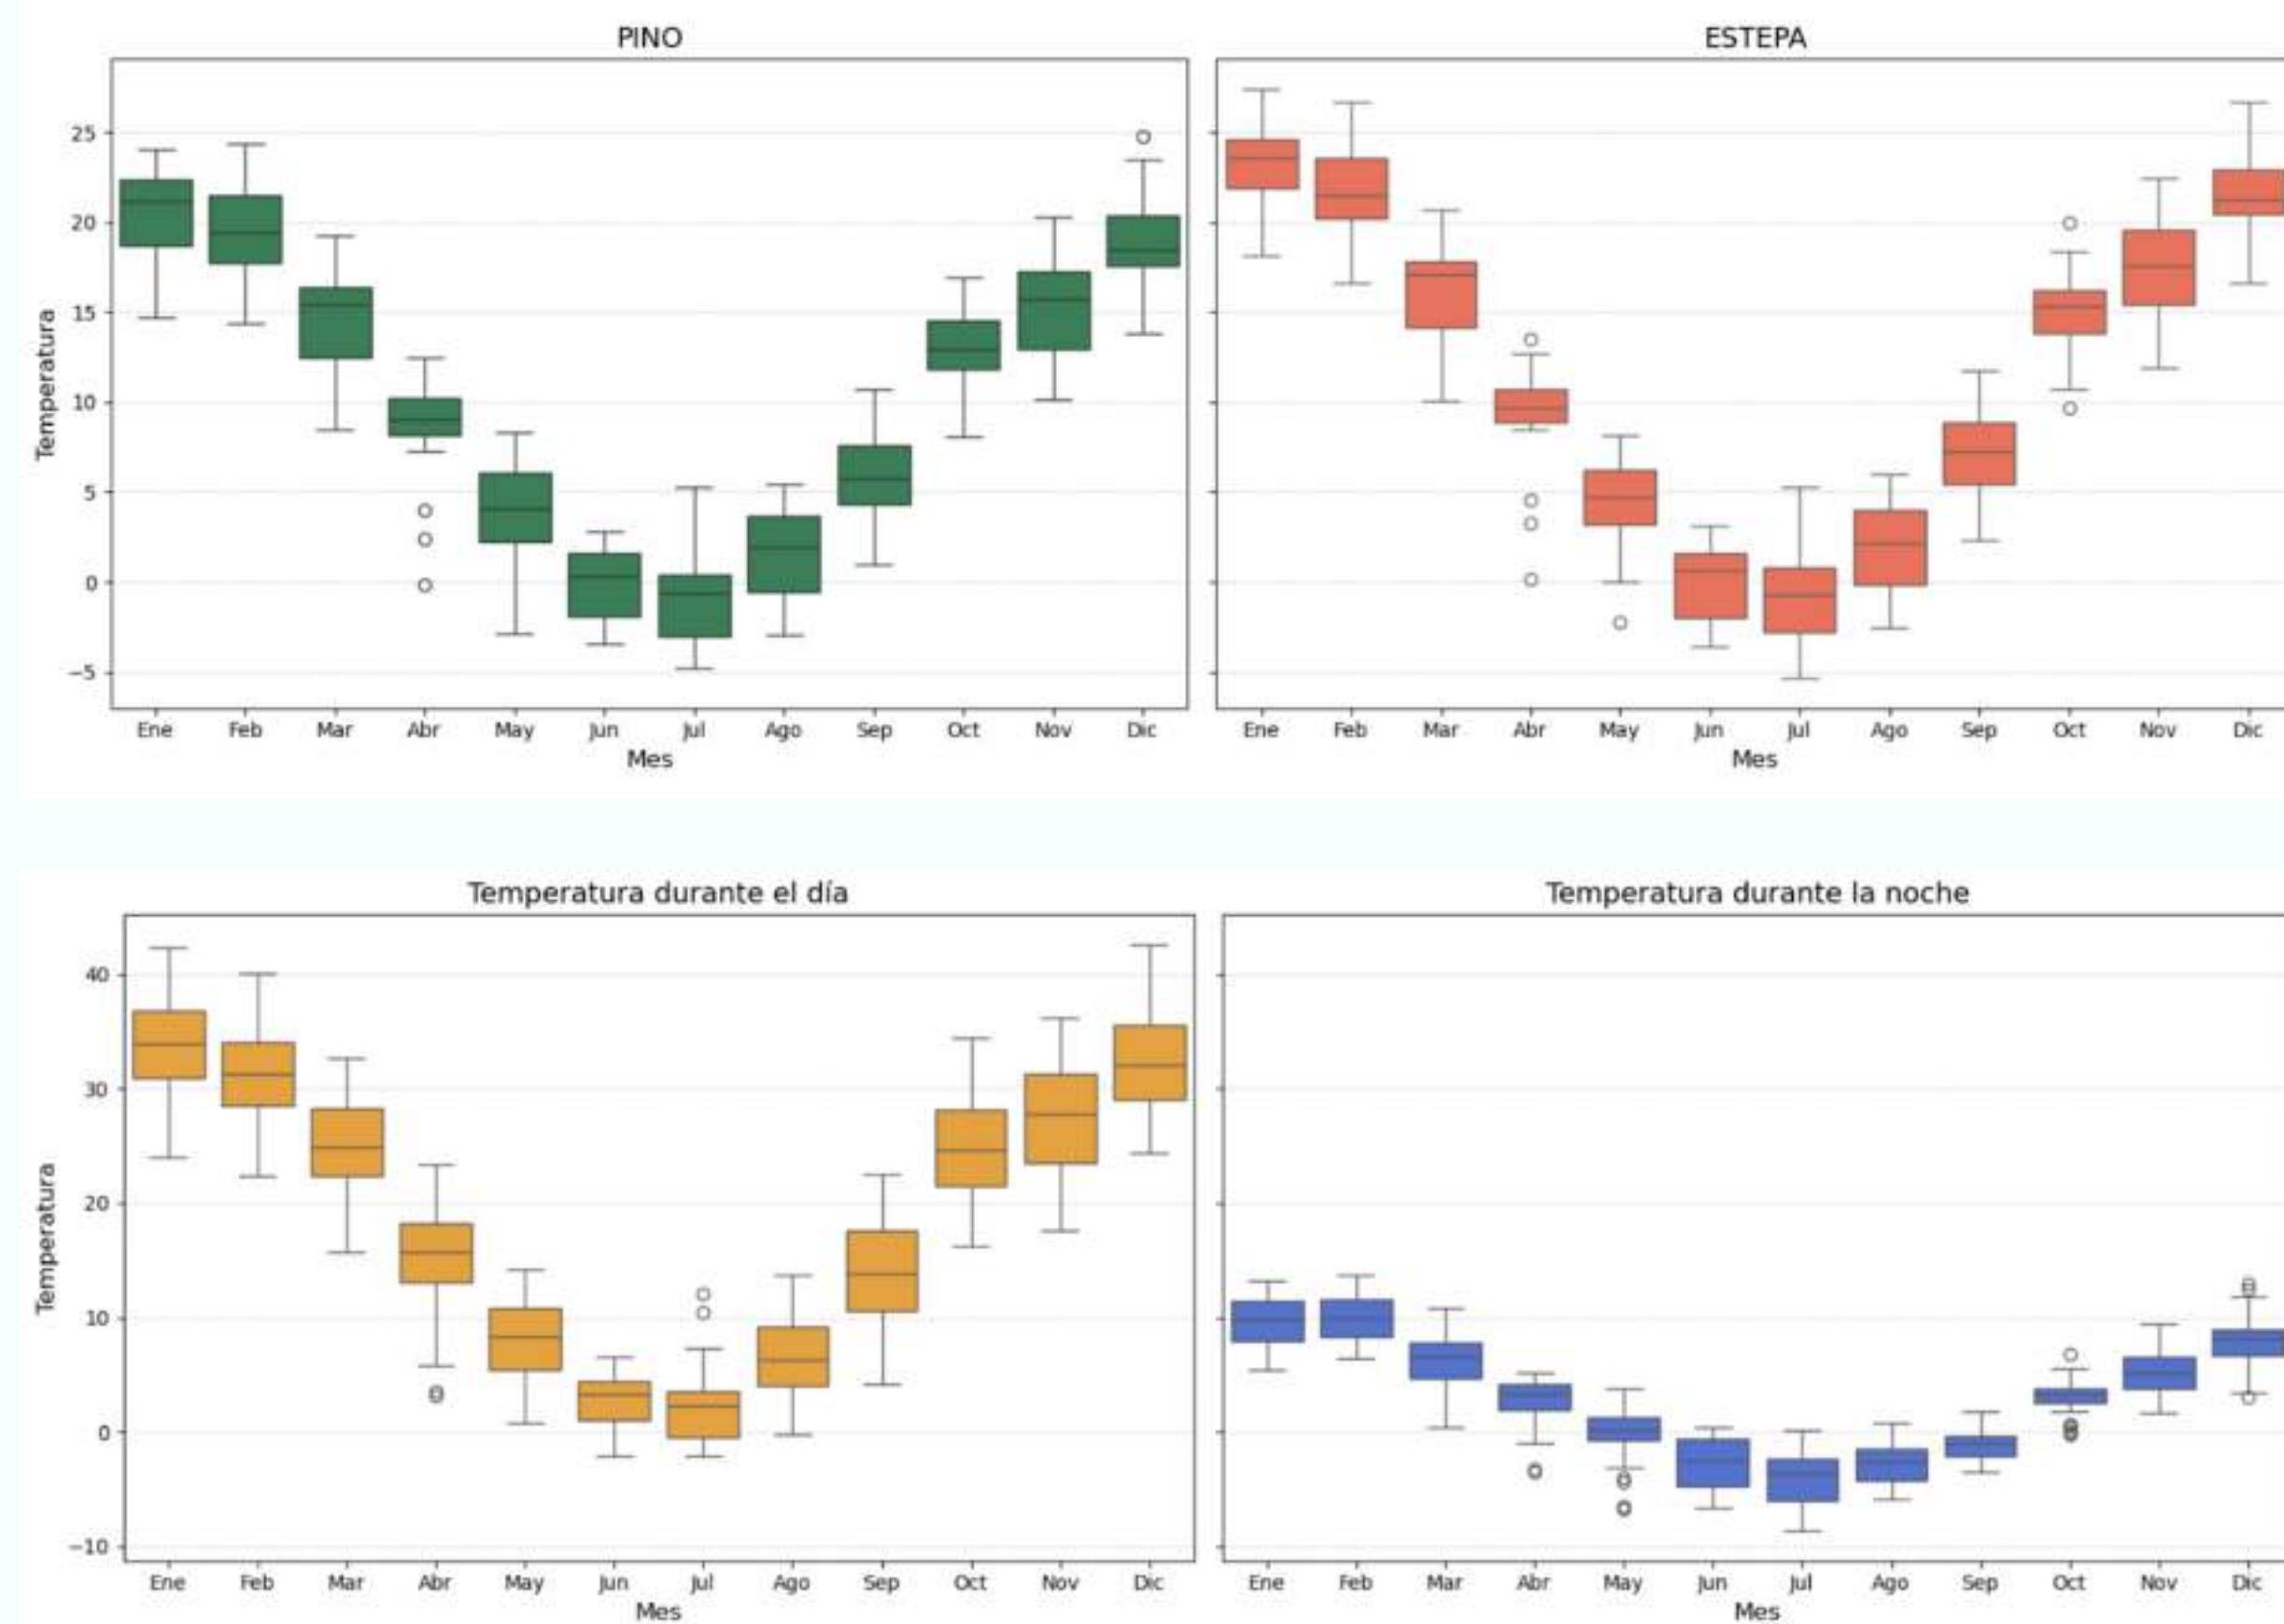
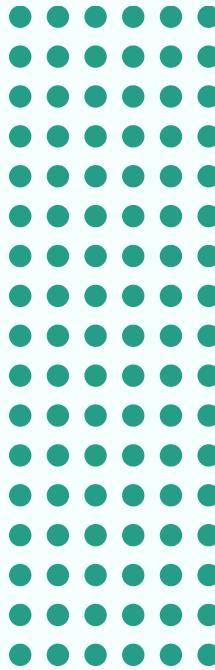
5 años de datos
(2020-2024)

Fuente: MODIS

Estimaciones de LST a
una resolución espacial
de 1 km y una temporal
de 8 días.



Trabajo realizado en AST I

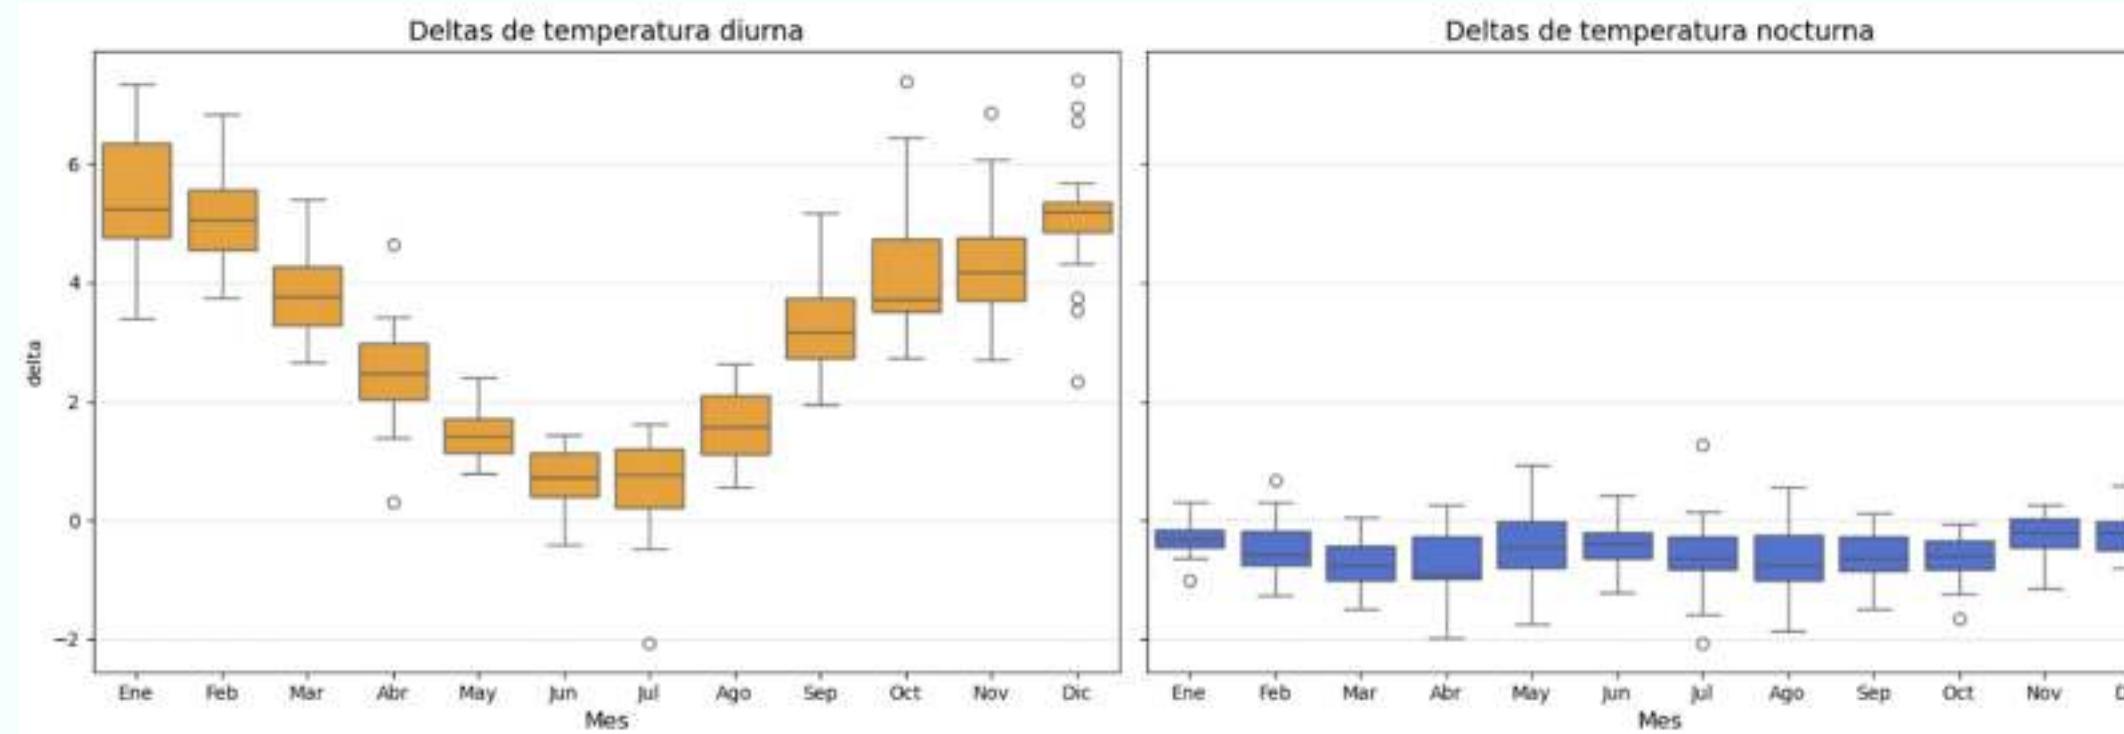
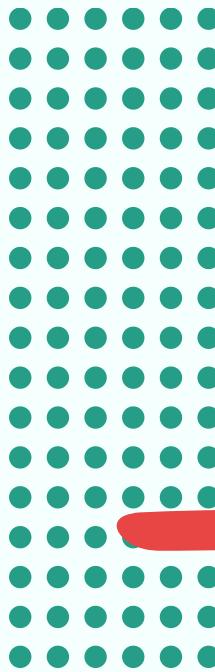
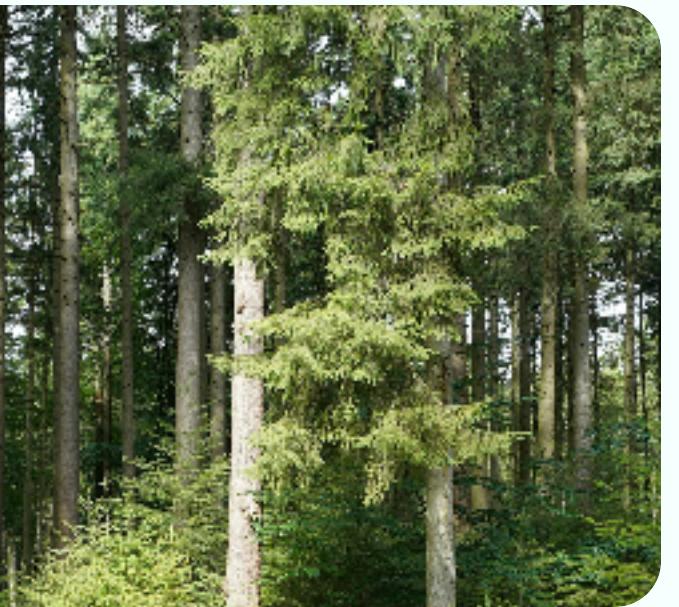


por cobertura

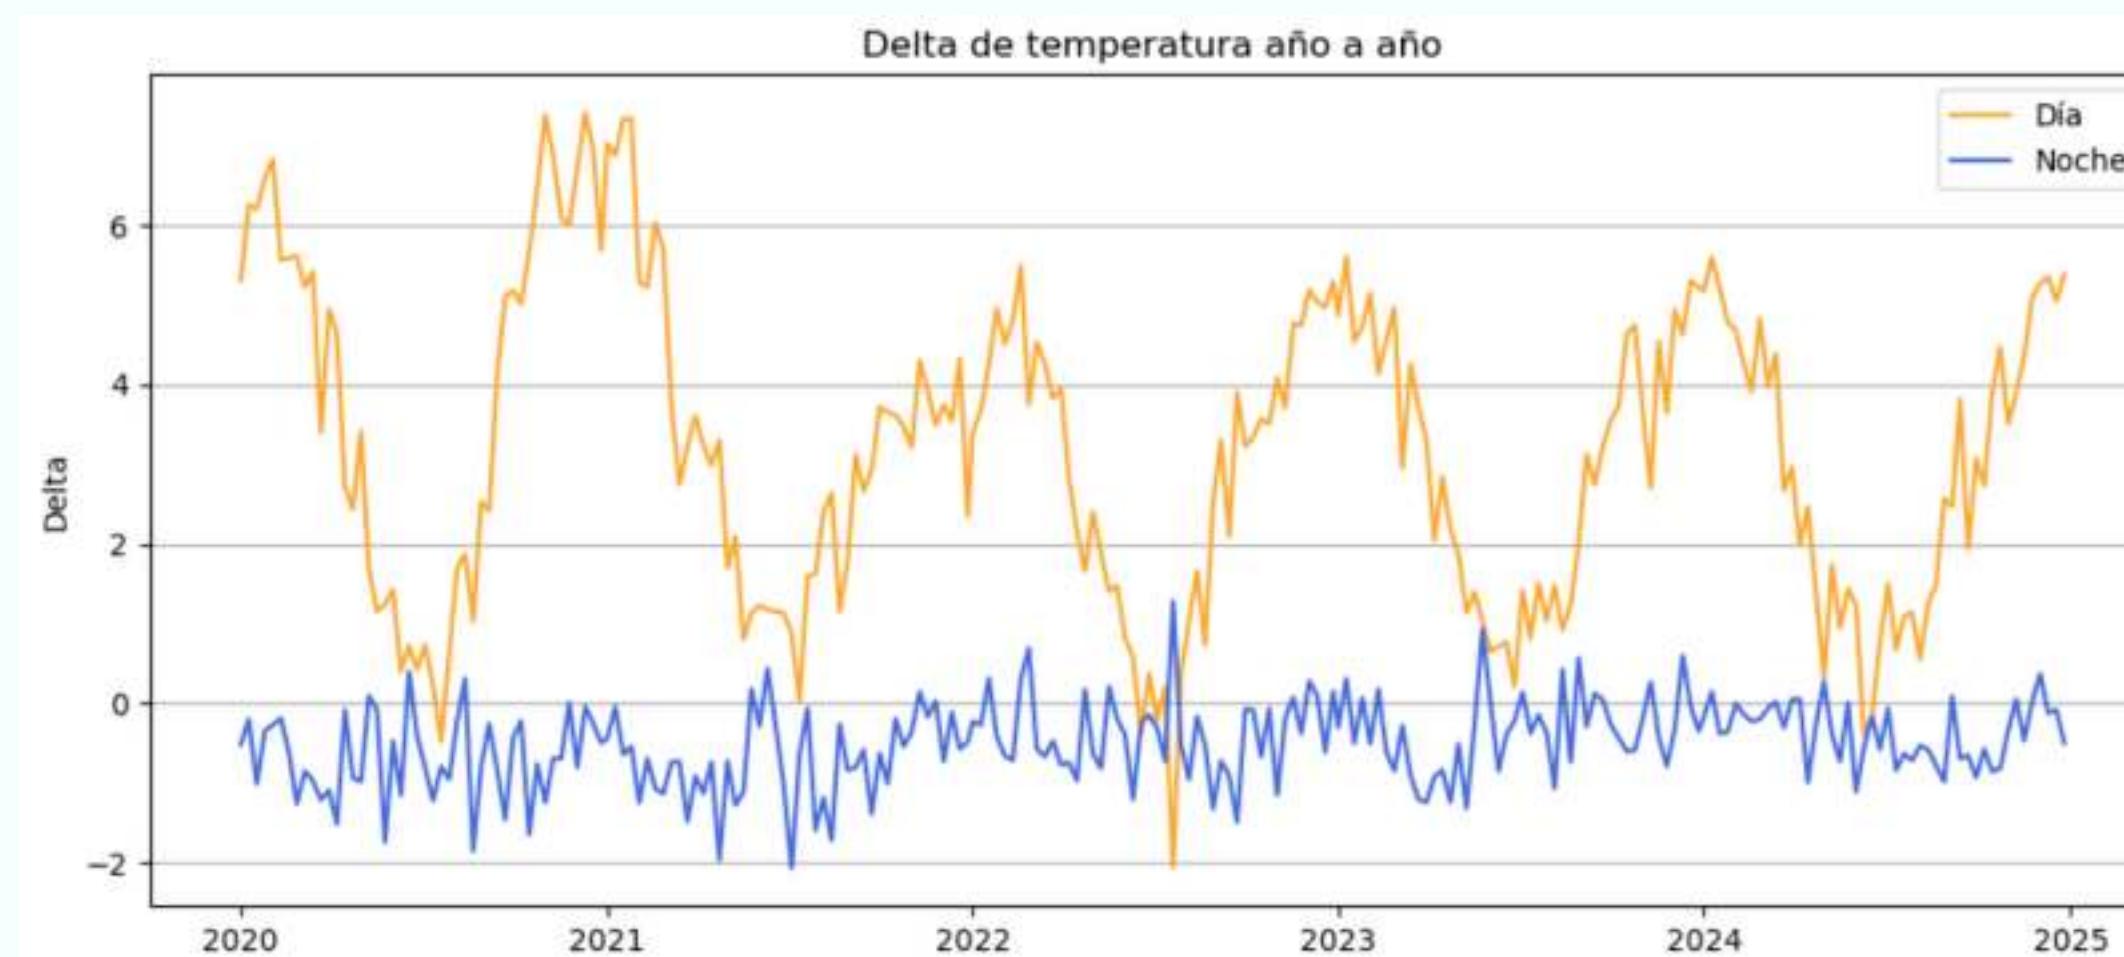


diurna / nocturna

Trabajo realizado en AST I



por mes



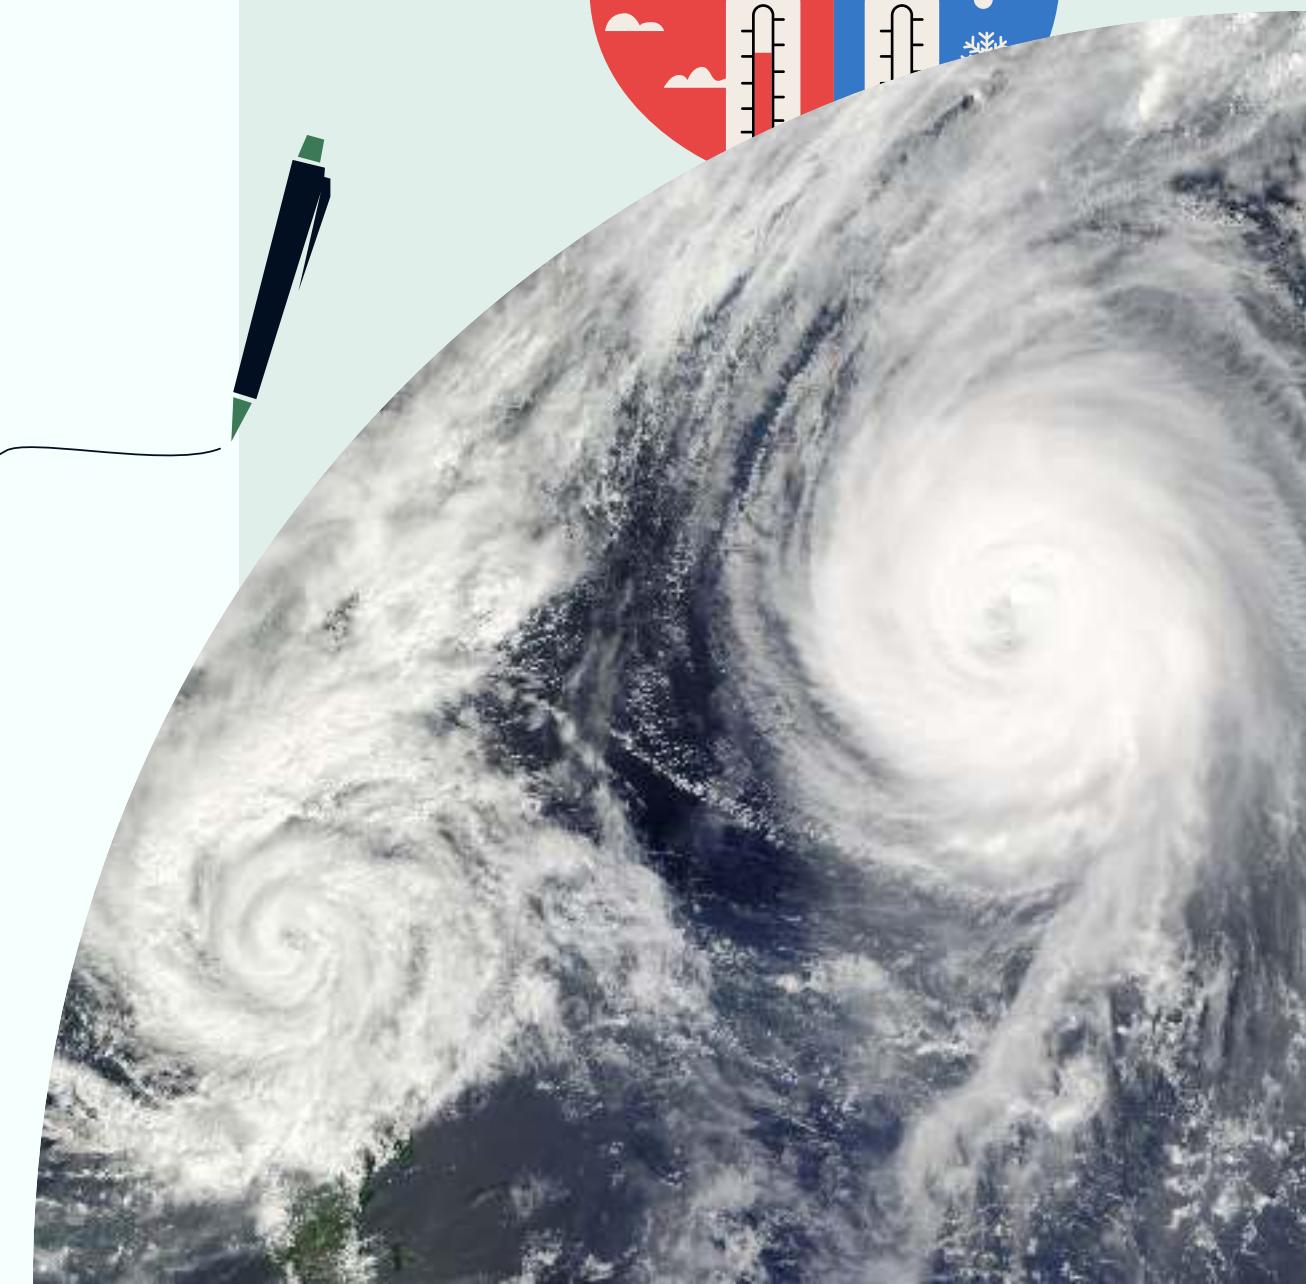
año a año

Trabajo realizado en ASTI

- **DATASET:** Serie temporal con resolución de 8 días.
- **MODELOS:** clásicos (SARIMA, Holt-Winters) y LSTM.

Trabajo futuro propuesto en ASTI

- **Mejorar el rendimiento del modelo LSTM:**
 - ajuste de hiperparámetros.
 - más datos de entrenamiento.
 - otros datos de entrenamiento (más granularidad).
 - variables externas (humedad, albedo, etc.).
- **Entrenar otras series (ej: deltas nocturnos)**

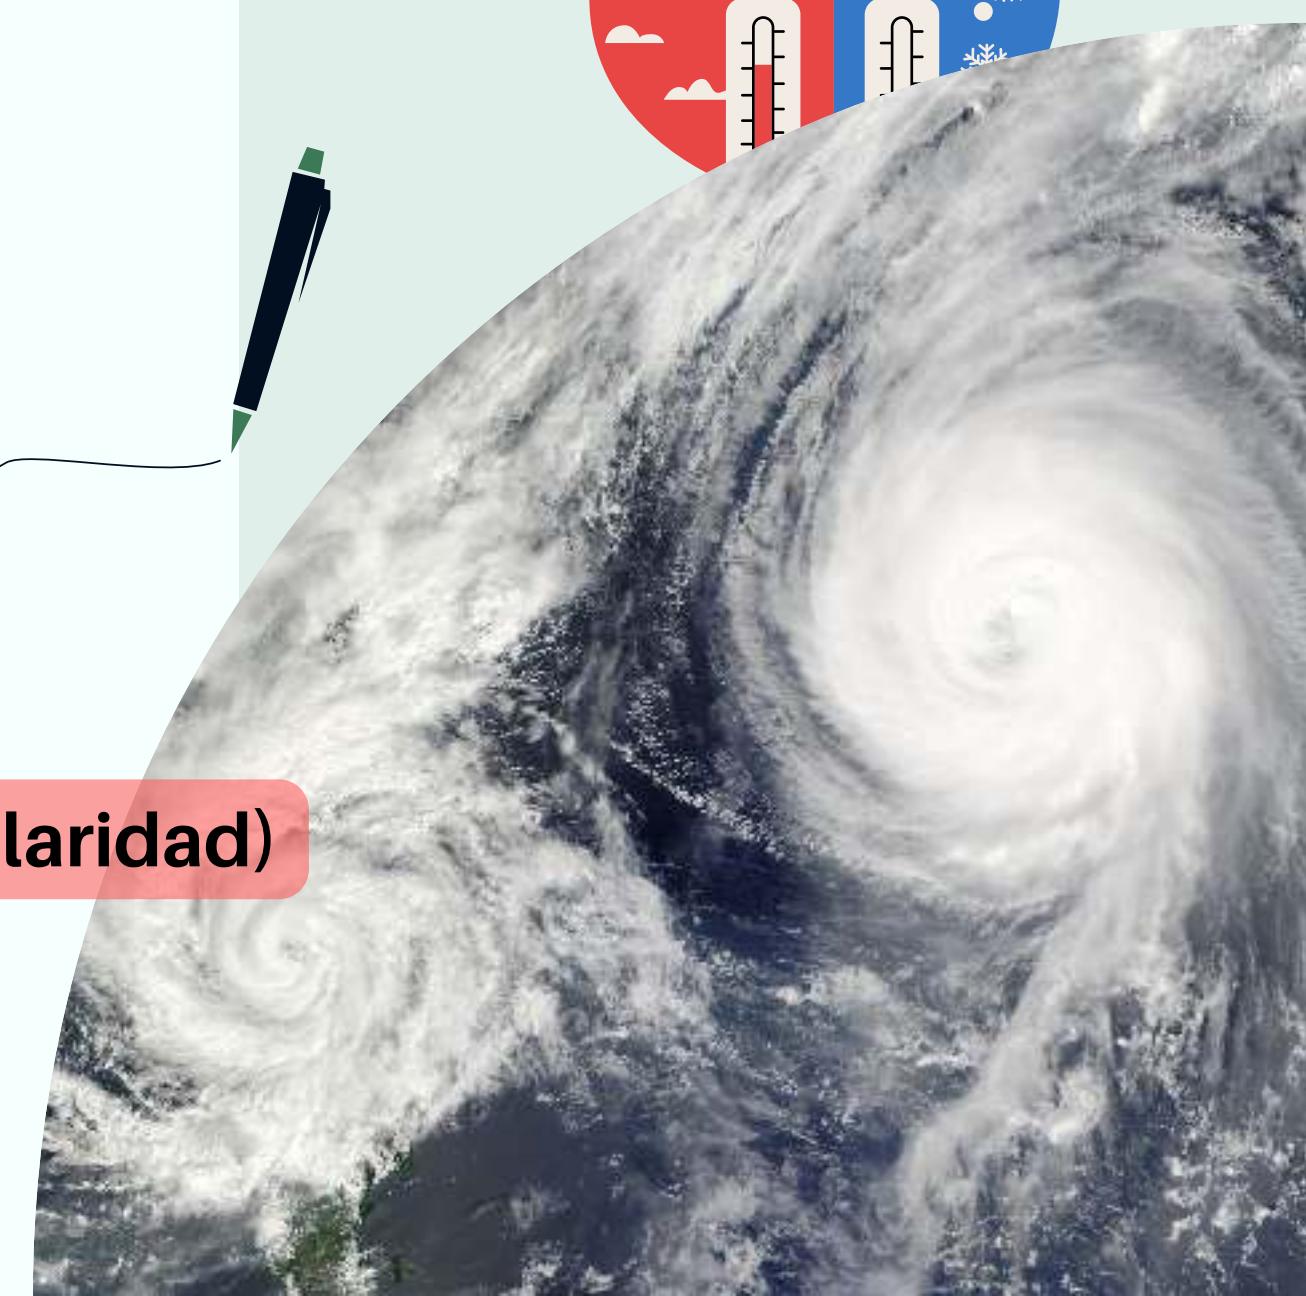


Trabajo realizado en ASTI

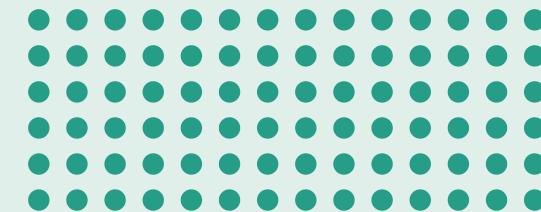
- **DATASET:** Serie temporal con resolución de 8 días.
- **MODELOS:** clásicos (SARIMA, Holt-Winters) y LSTM.

Trabajo futuro propuesto en ASTI

- Mejorar el rendimiento del modelo:
 - ajuste de hiperparámetros
 - más datos de entrenamiento.
 - otros datos de entrenamiento (más granularidad)
 - variables externas (humedad, albedo, etc.).
- Entrenar otras series (ej: deltas nocturnos)
- entrenar otros modelos



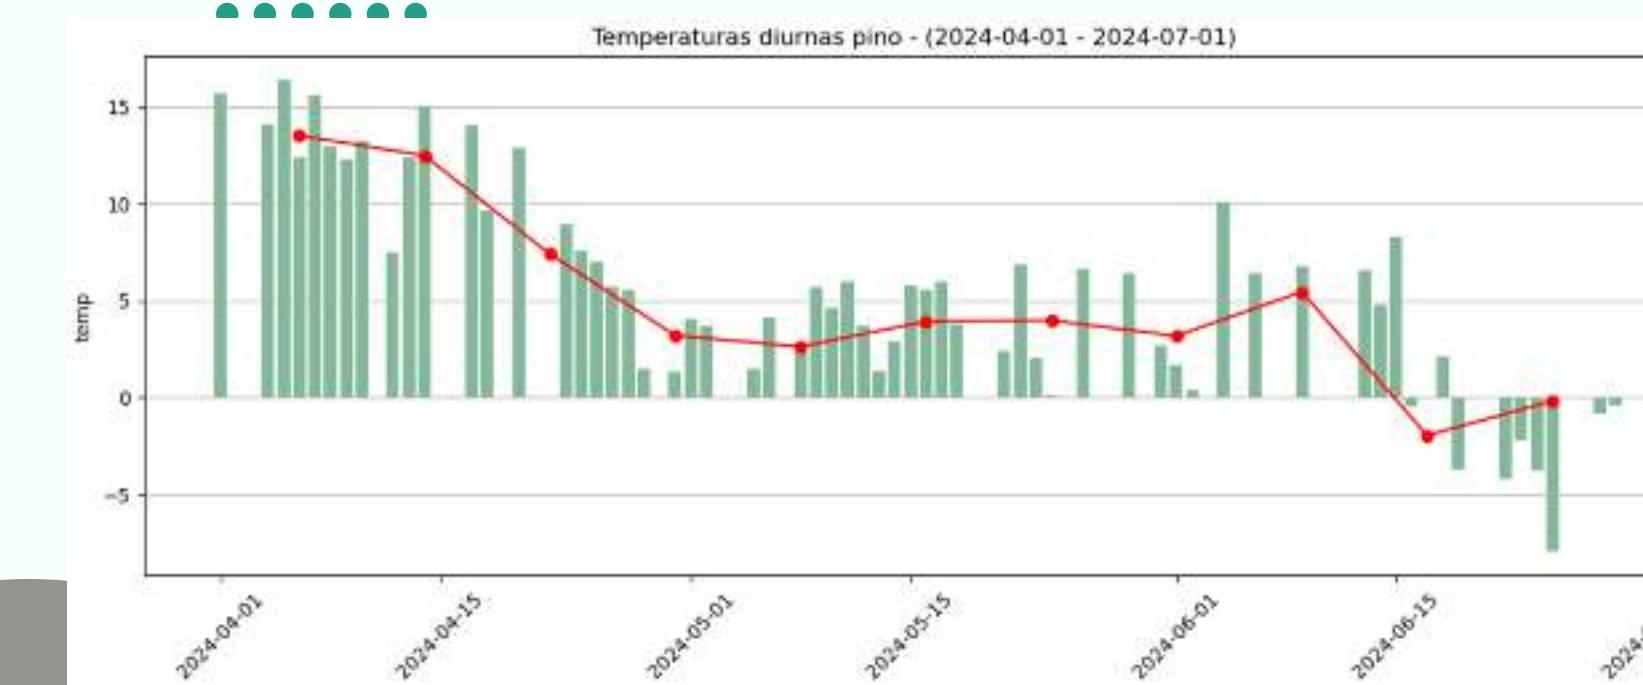
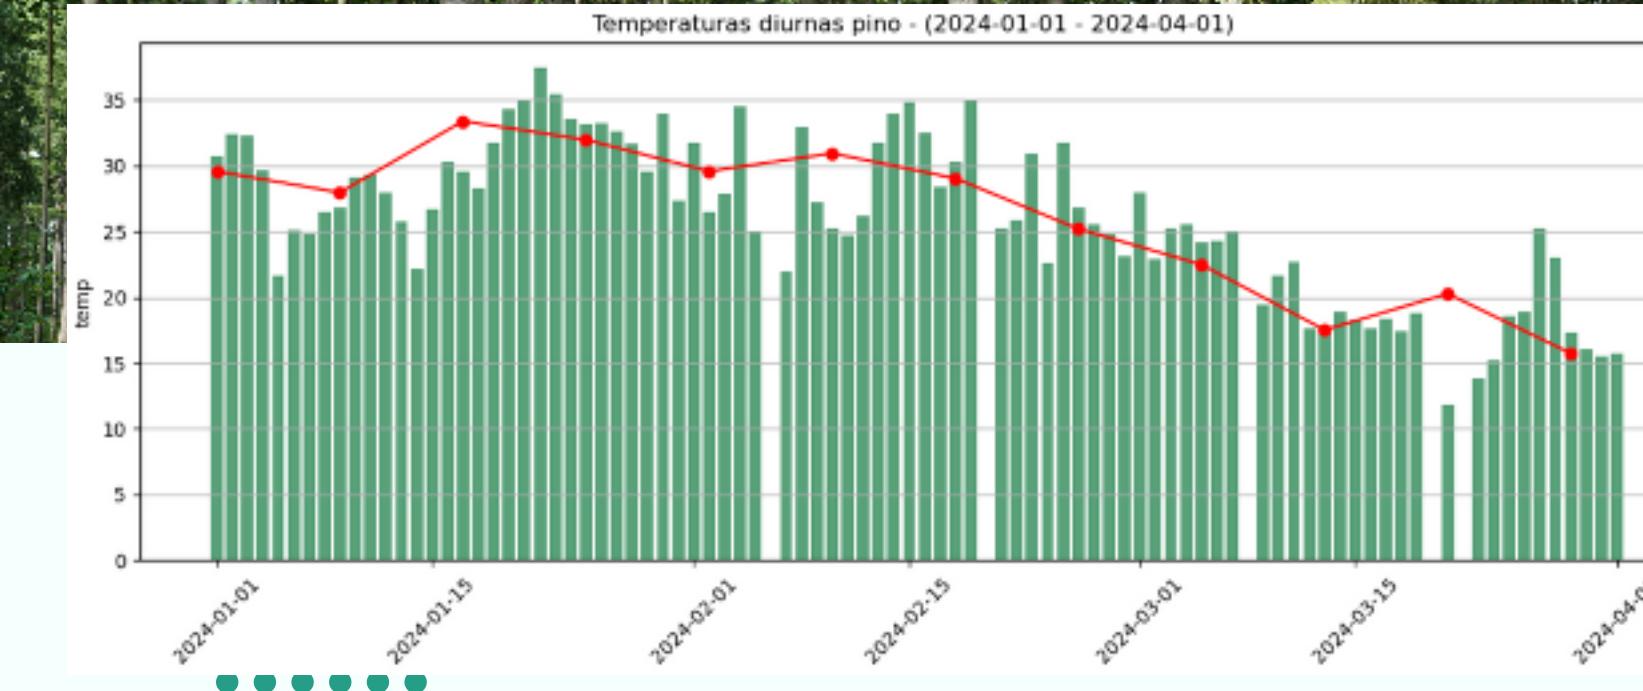
Datos procesados (LST día)



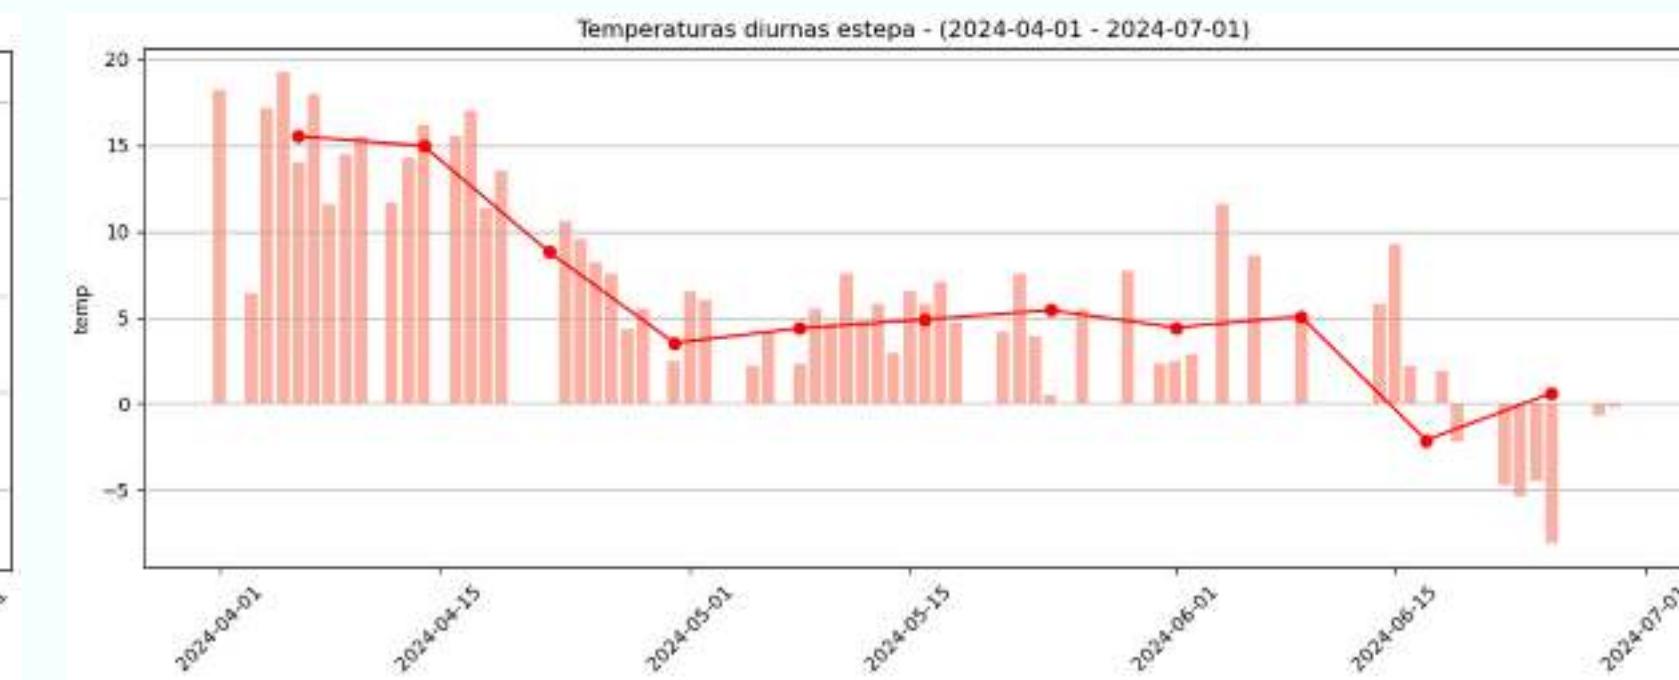
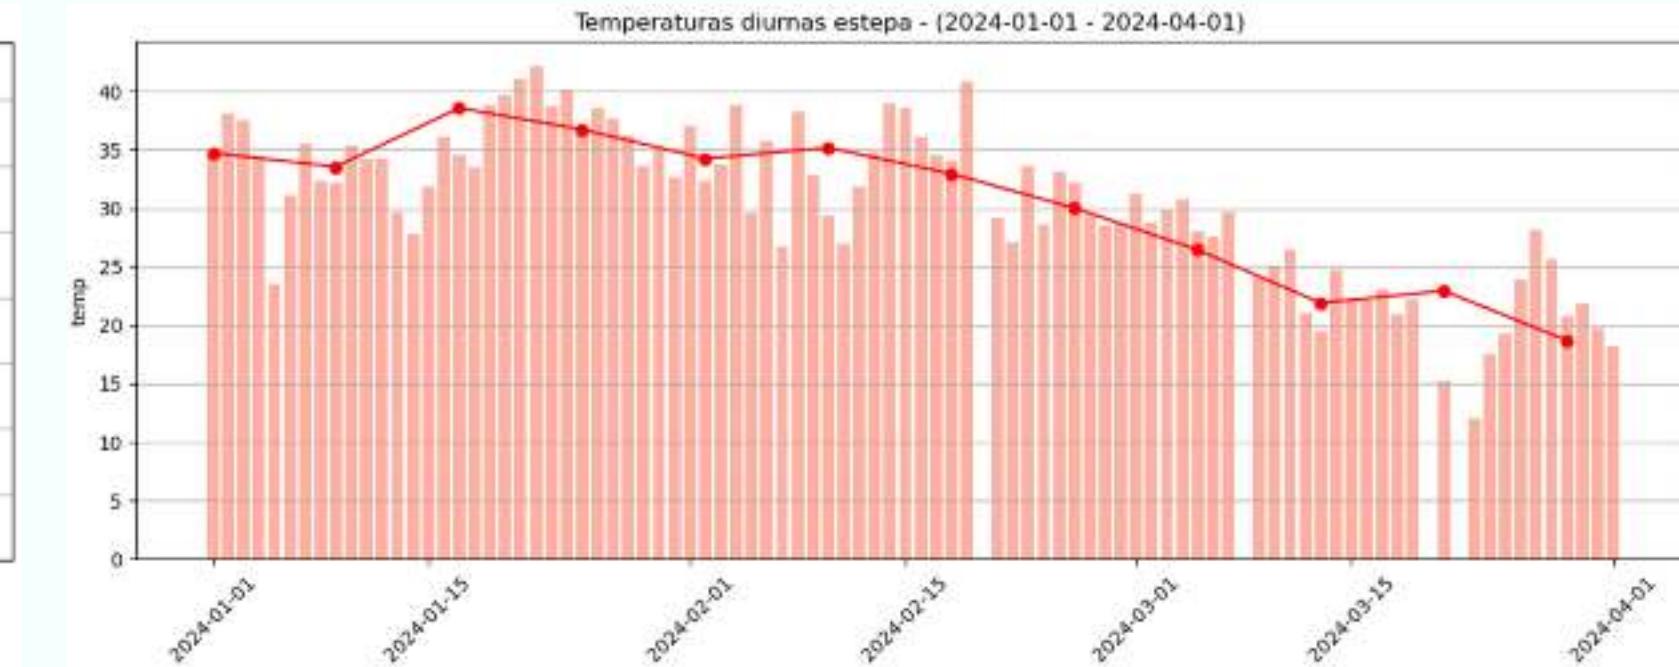
columna	descripción	valores	formato
fecha	fecha	día, mes y año	yyyy-mm-dd
estepa	temperatura diurna de superficie de la estepa	grados celsius	numérico
pino	temperatura diurna de superficie del pino	grados celsius	numérico
mes	número de mes (enero 1, febrero 2, etc.) Es una columna auxiliar para los gráficos.	[1..12]	numérico
delta	delta de temperatura diaria, calculada como estepa - pino	grados celsius	texto

fecha	estepa	pino	mes	delta
2020-01-01	35.433453	33.666374	1	1.767079
2020-01-02	36.195872	31.342840	1	4.853032
2020-01-03	35.245773	31.284172	1	3.961601
2020-01-04	38.821326	31.450303	1	7.371023
2020-01-05	NaN	17.944593	1	NaN
...
2024-12-27	35.852191	29.409928	12	6.442263
2024-12-28	34.259605	33.732374	12	0.527231
2024-12-29	38.103253	32.029511	12	6.073742
2024-12-30	27.980279	25.945808	12	2.034471
2024-12-31	25.818976	20.606843	12	5.212133

LST por tipo de cobertura



pino



estepa

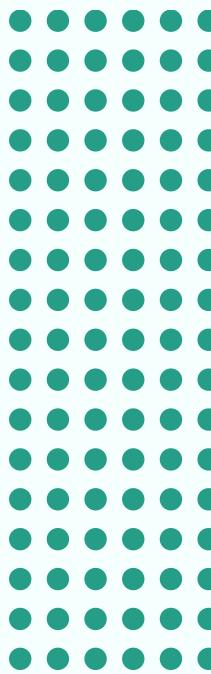
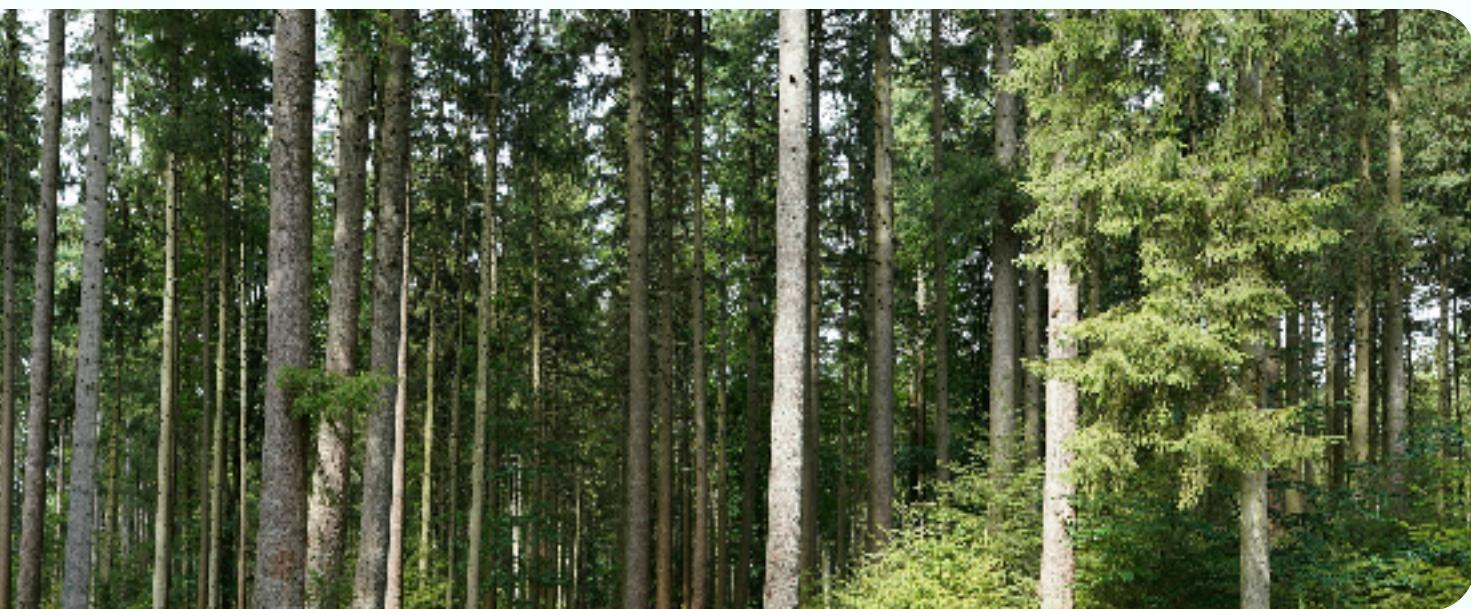
15 %
faltantes



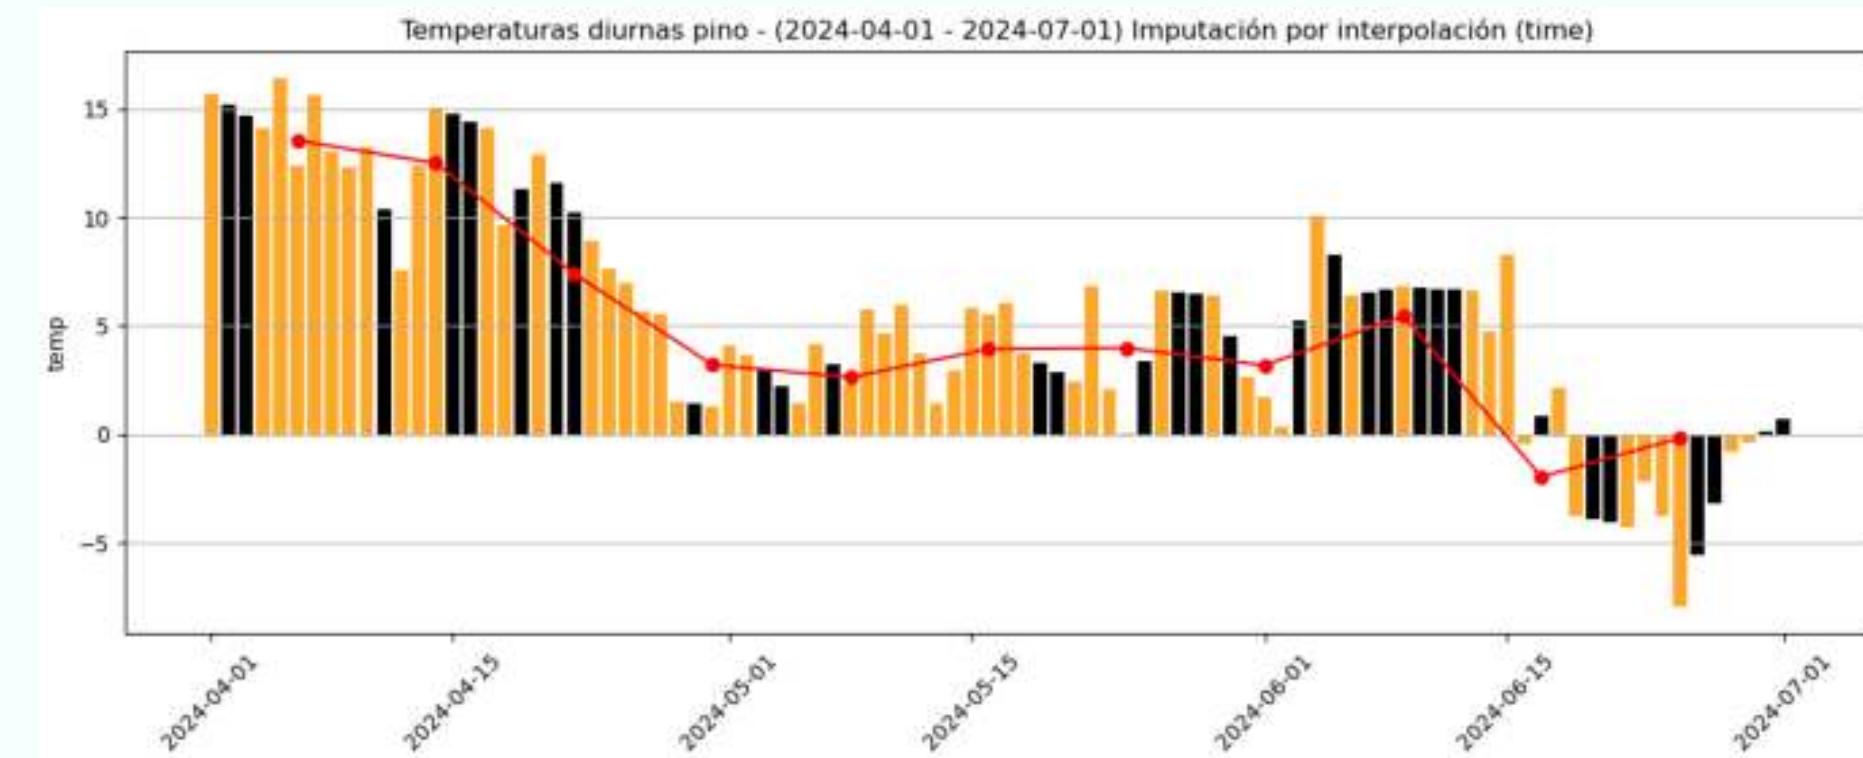
Imputación de faltantes

Interpolación método ‘time’

Interpolación asumiendo una variación lineal en función del tiempo.



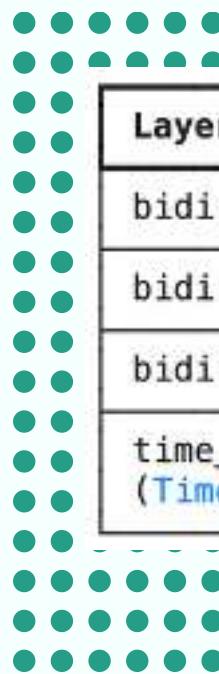
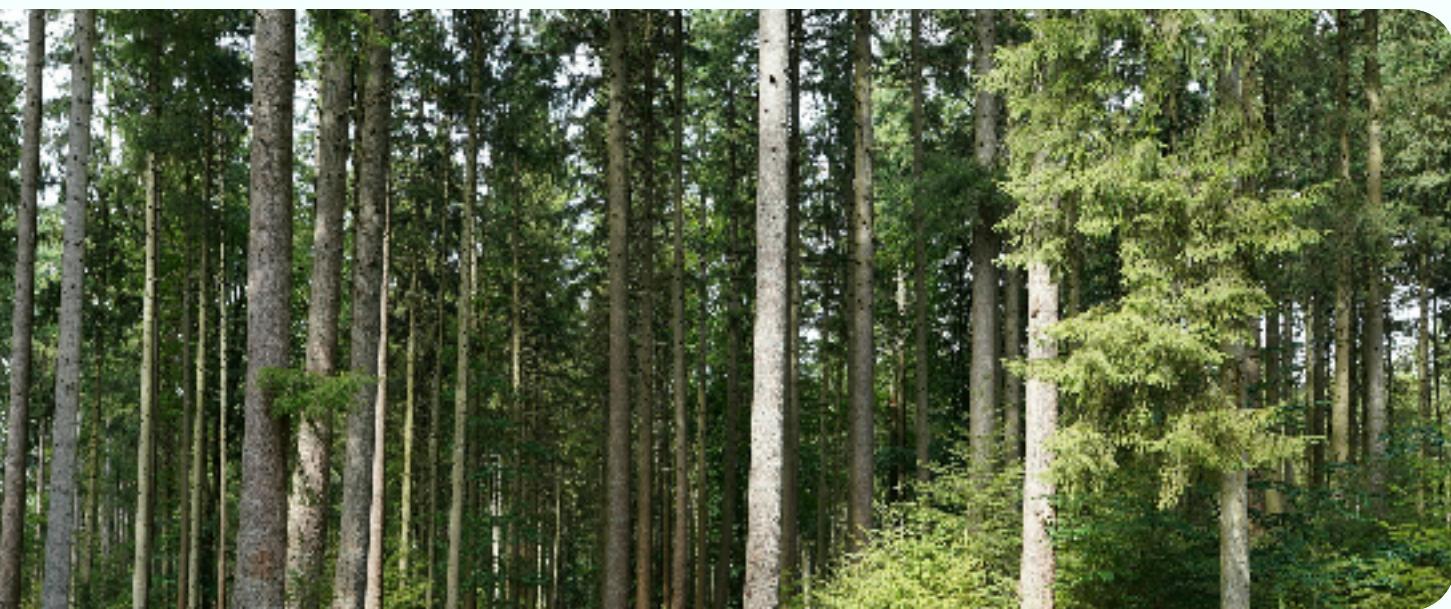
- Rellena valores faltantes (NaN).
- La estimación se basa en la información de tiempo (índice)
- Calcula valores intermedios proporcionalmente entre puntos conocidos.



Imputación de faltantes

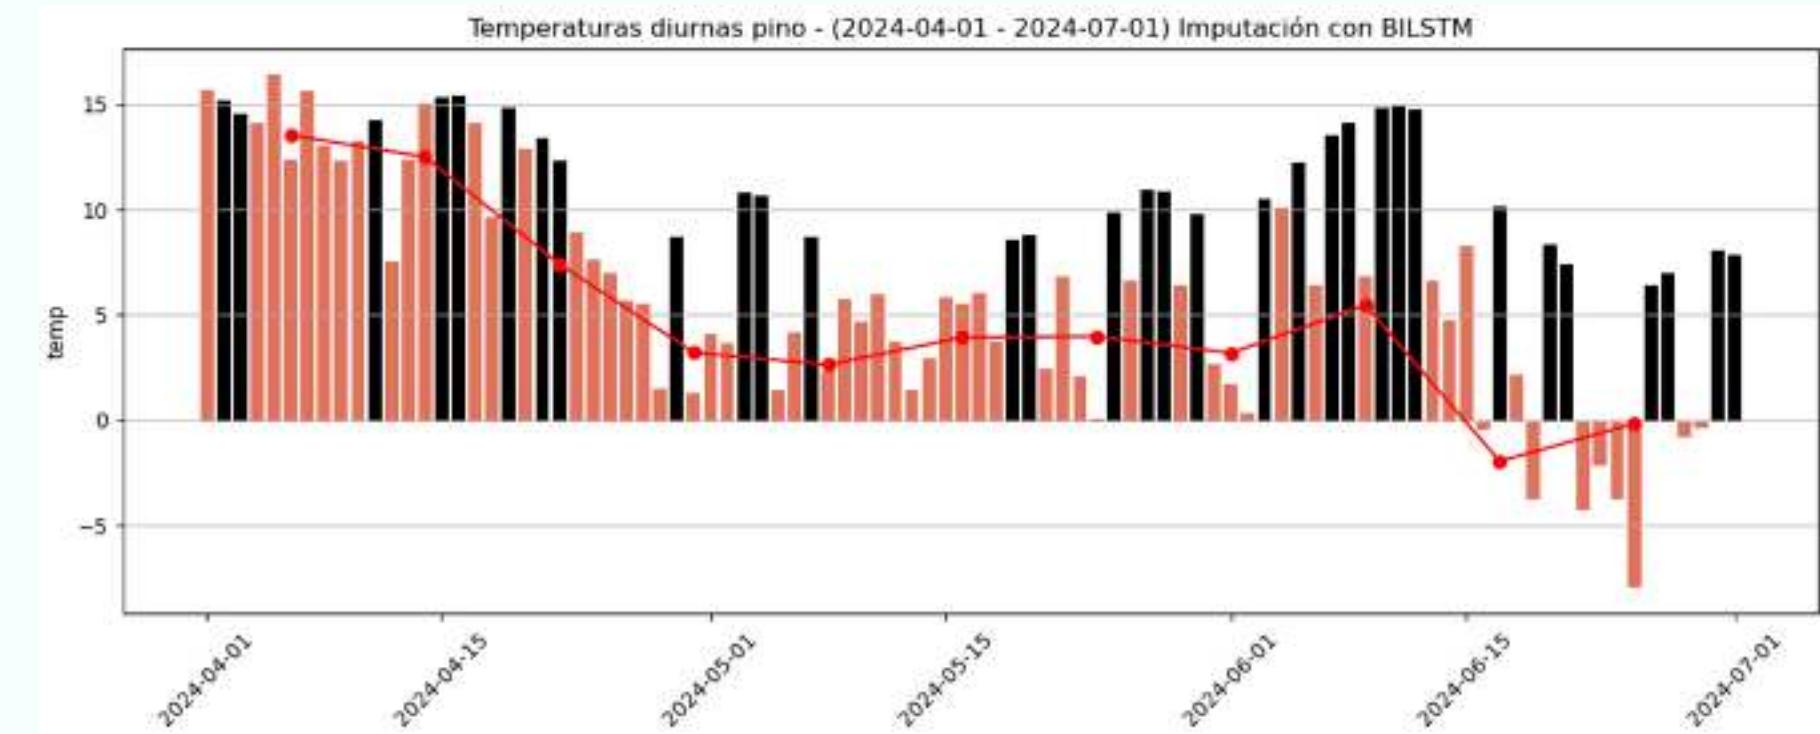
Imputación BiLSTM

Aprende patrones temporales hacia adelante y hacia atrás.



Layer (type)	Output Shape	Param #
bidirectional (Bidirectional)	(None, None, 256)	134,144
bidirectional_1 (Bidirectional)	(None, None, 128)	164,352
bidirectional_2 (Bidirectional)	(None, None, 64)	41,216
time_distributed (TimeDistributed)	(None, None, 2)	130

- optimizador: Adam
- learning rate: 0.0005
- loss: MSE
- EarlyStopping (patience=15)
- epochs: 200



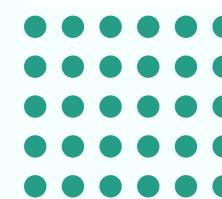
- Entrenamiento: falta de datos artificial (15 %)

Imputación de faltantes

Imputación BiLSTM



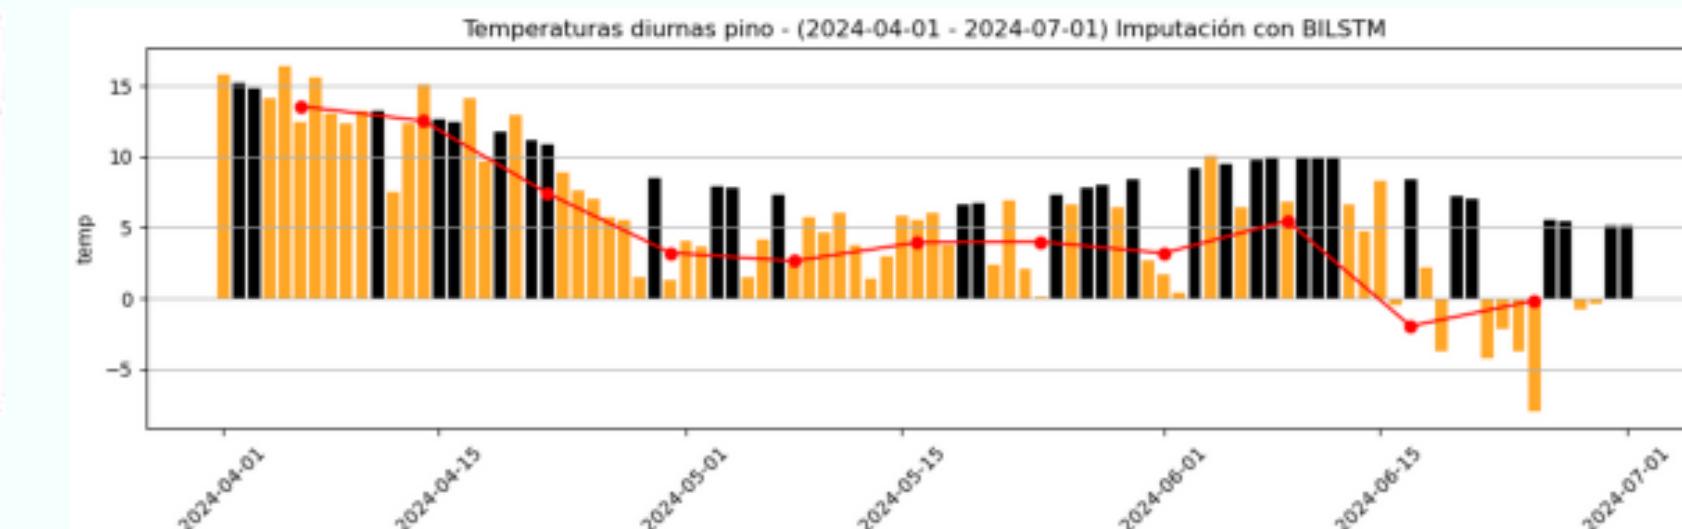
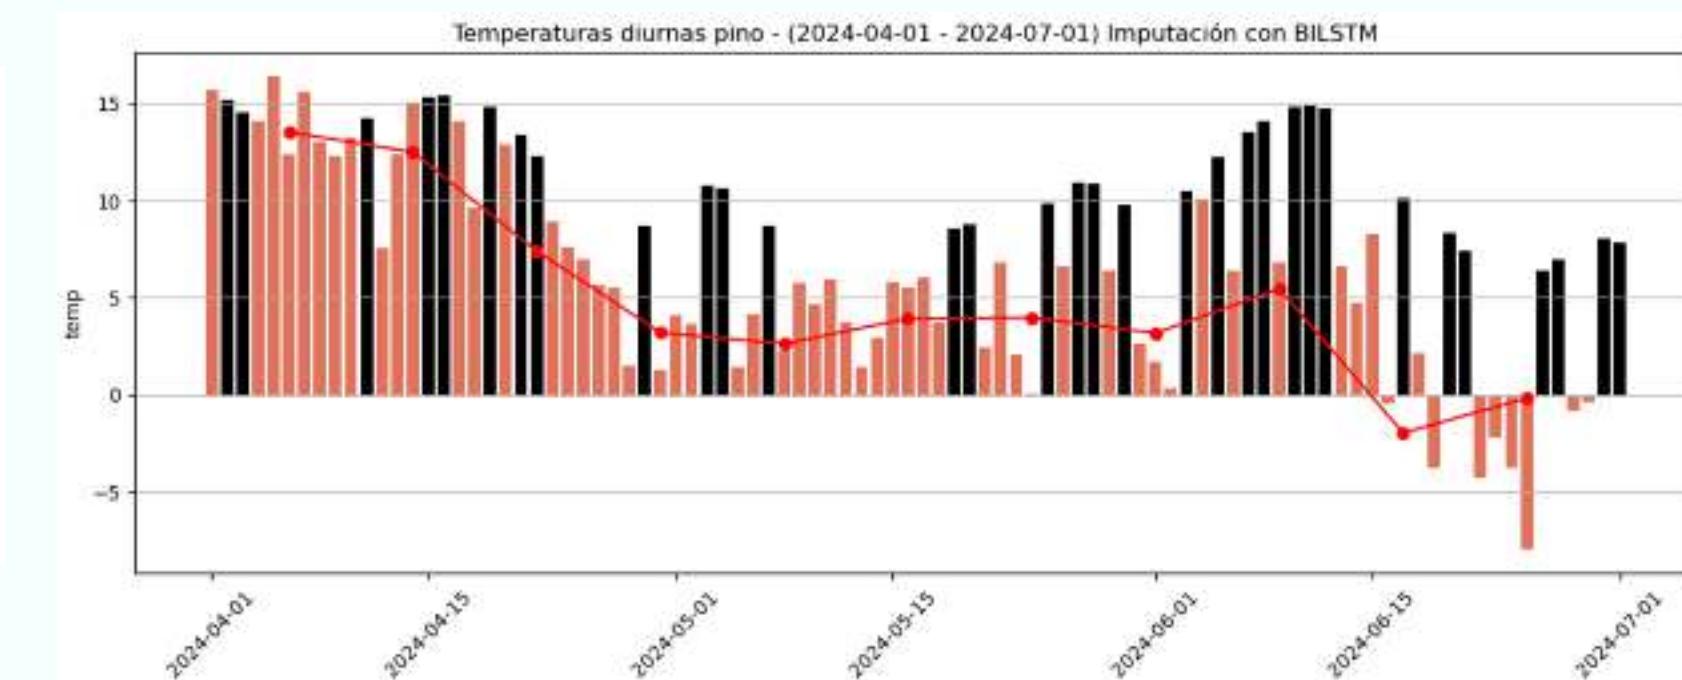
Layer (type)	Output Shape	Param #
bidirectional (Bidirectional)	(None, None, 256)	134,144
bidirectional_1 (Bidirectional)	(None, None, 128)	164,352
bidirectional_2 (Bidirectional)	(None, None, 64)	41,216
time_distributed (TimeDistributed)	(None, None, 2)	130



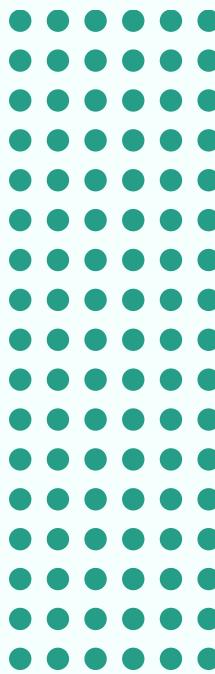
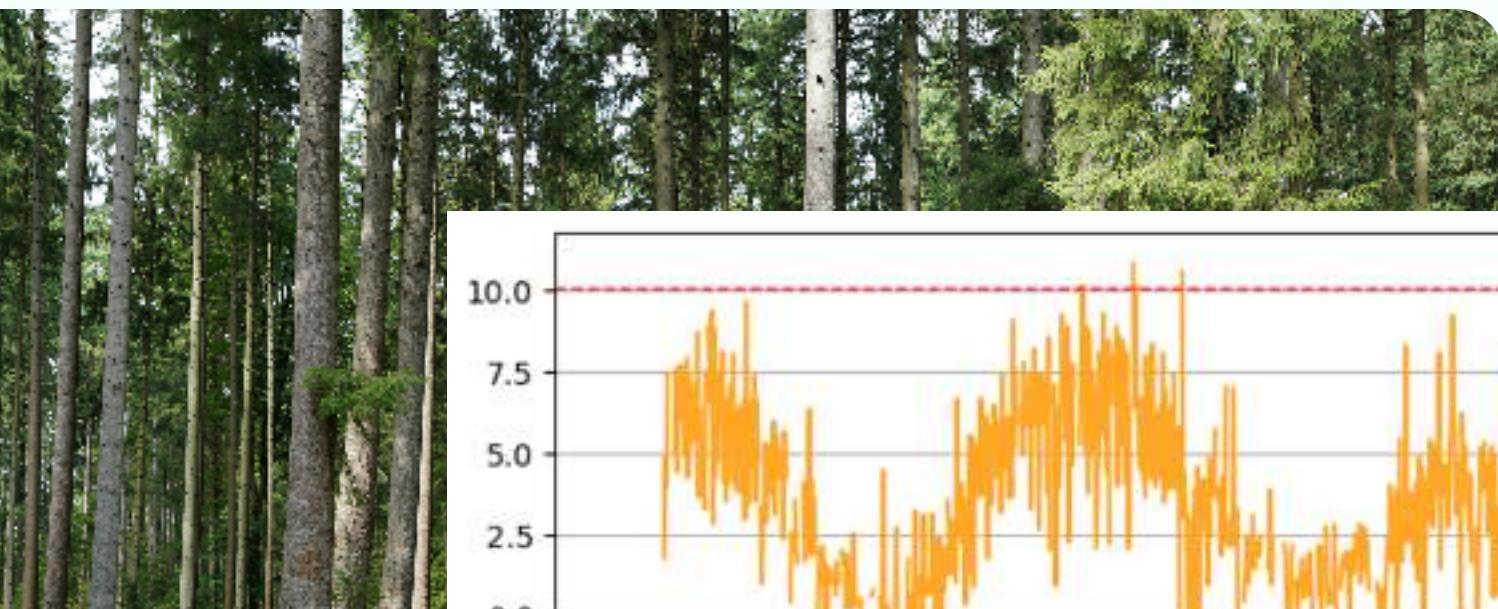
Layer (type)	Output Shape	Param #
bidirectional_3 (Bidirectional)	(None, None, 128)	35,328
bidirectional_4 (Bidirectional)	(None, None, 64)	41,216
time_distributed_1 (TimeDistributed)	(None, None, 2)	130

MAE estepa: 4.315 °C (33.08 % relativo a std)

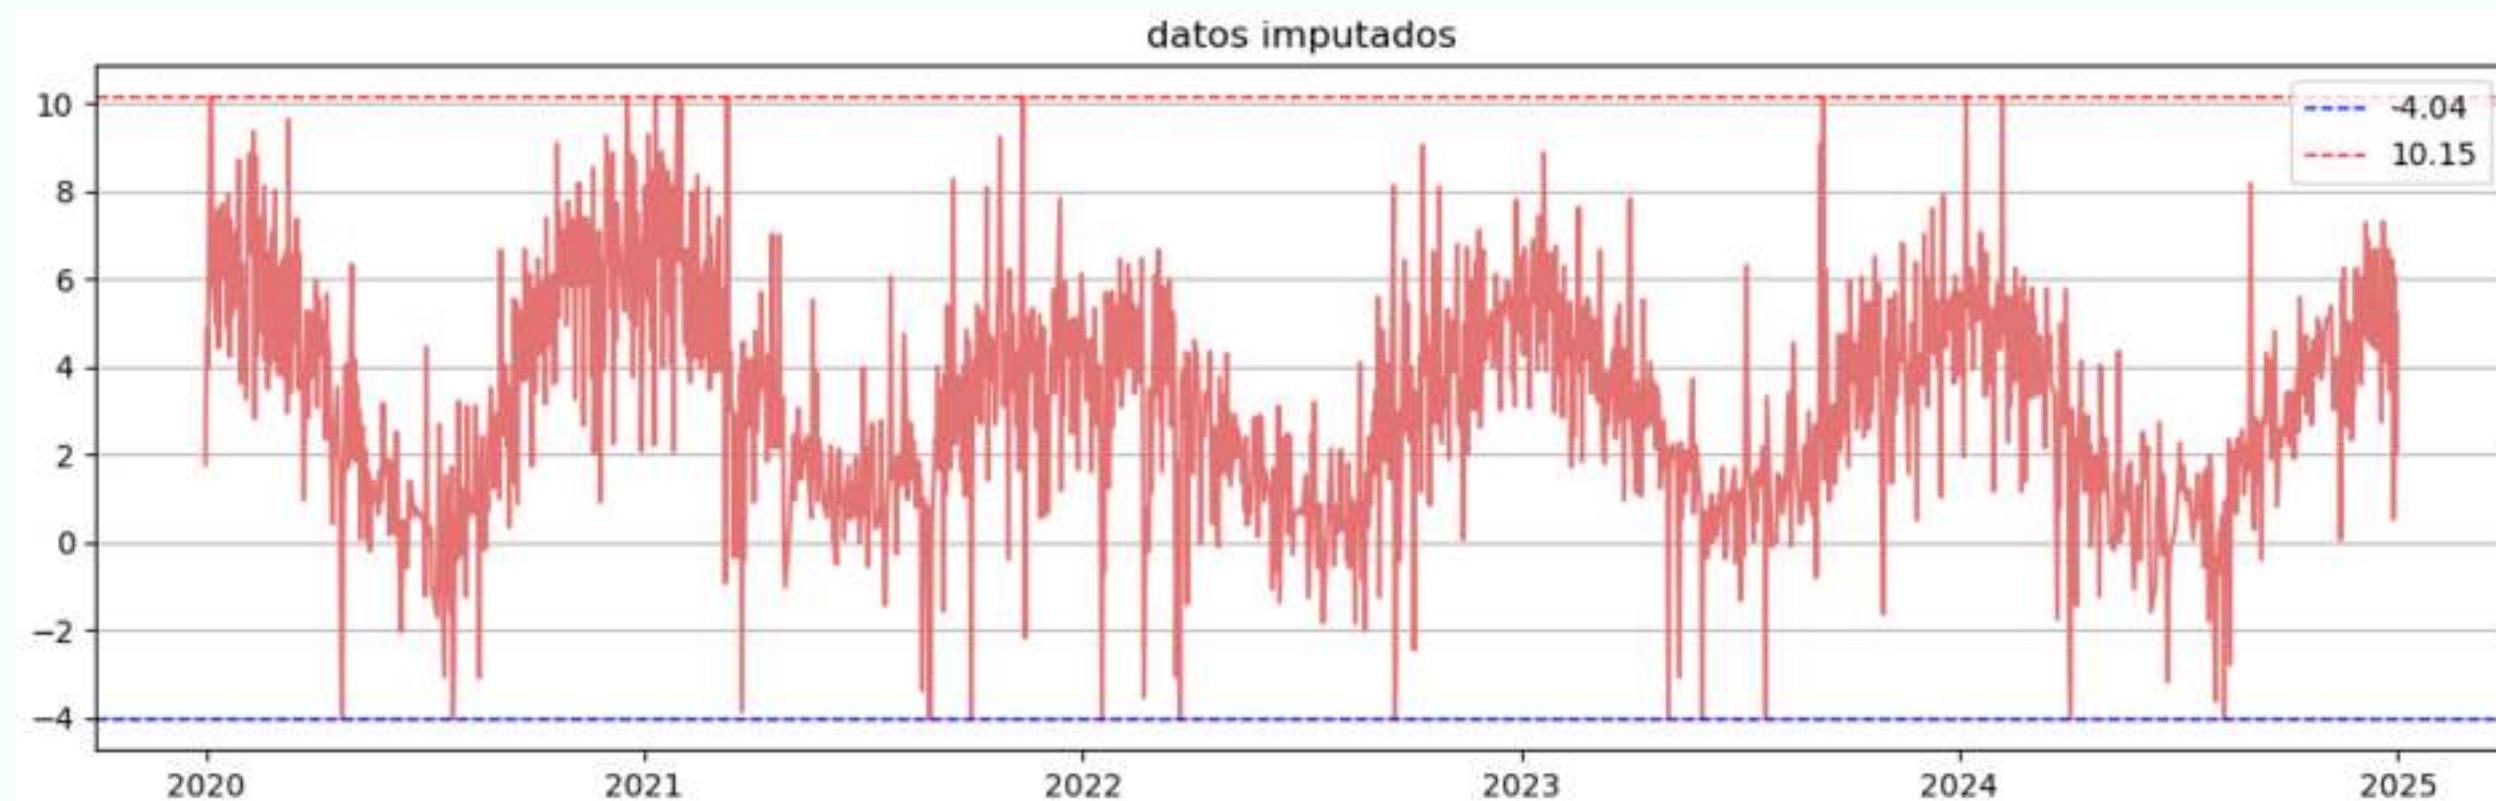
MAE pino: 3.545 °C (31.12 % relativo a std)



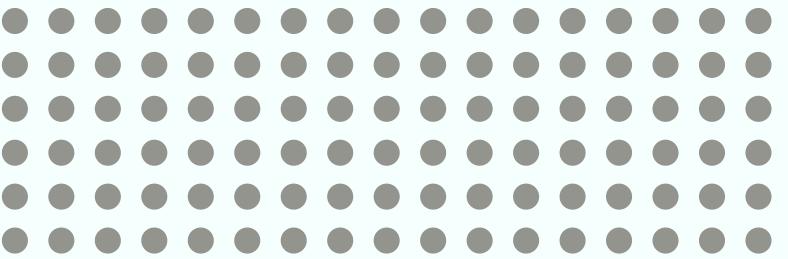
Imputación de faltantes



datos originales



datos imputados
con BiLSTM + clip
de outliers



Modelos predictivos para el delta LST diurno

Holt-Winters
(baseline)

LSTM

GRU

TRANSFORMER



O P T U N A



TensorFlow

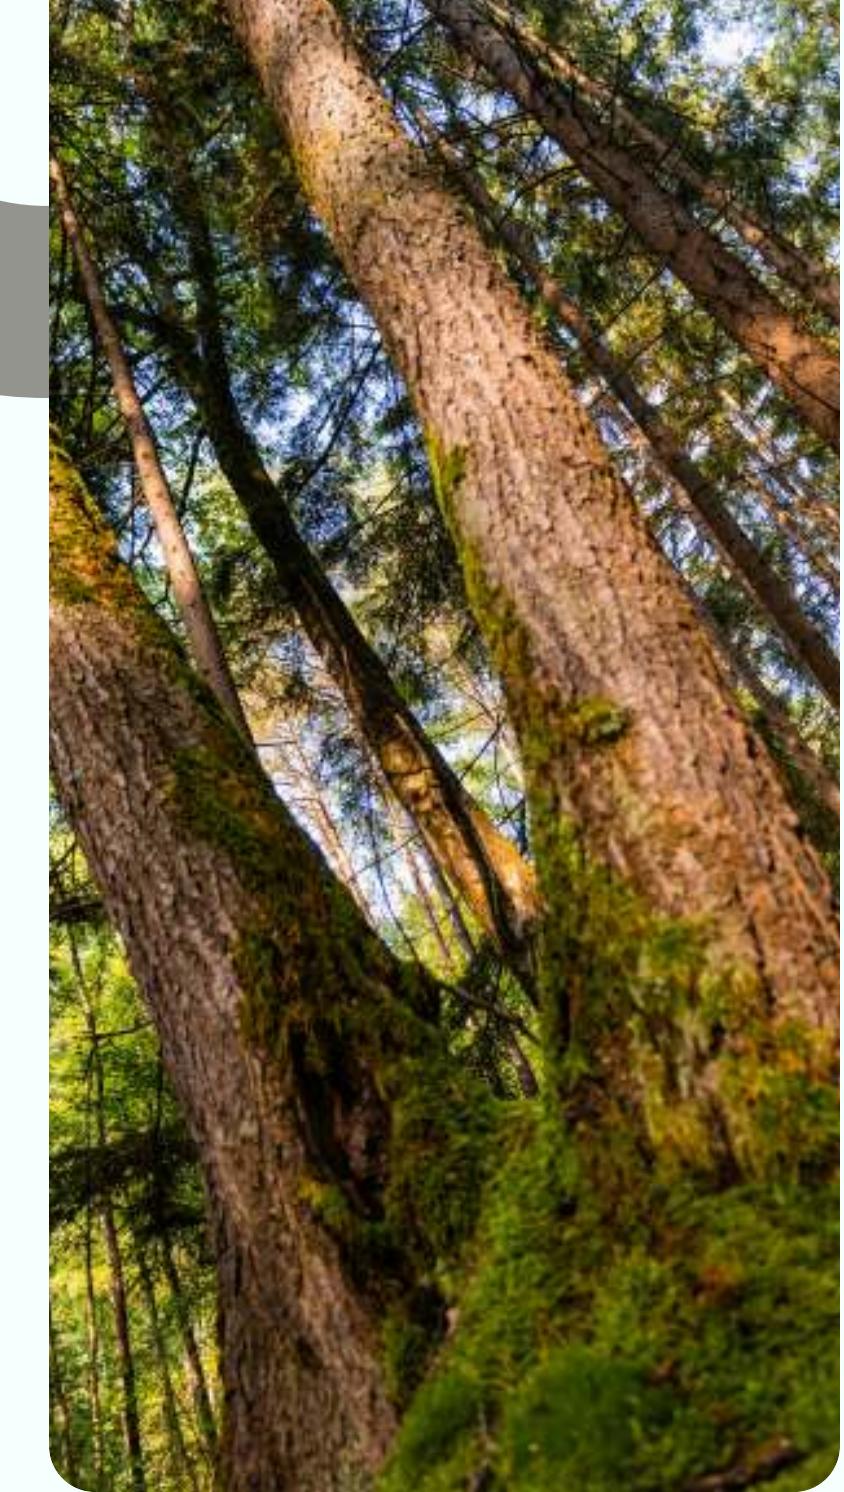
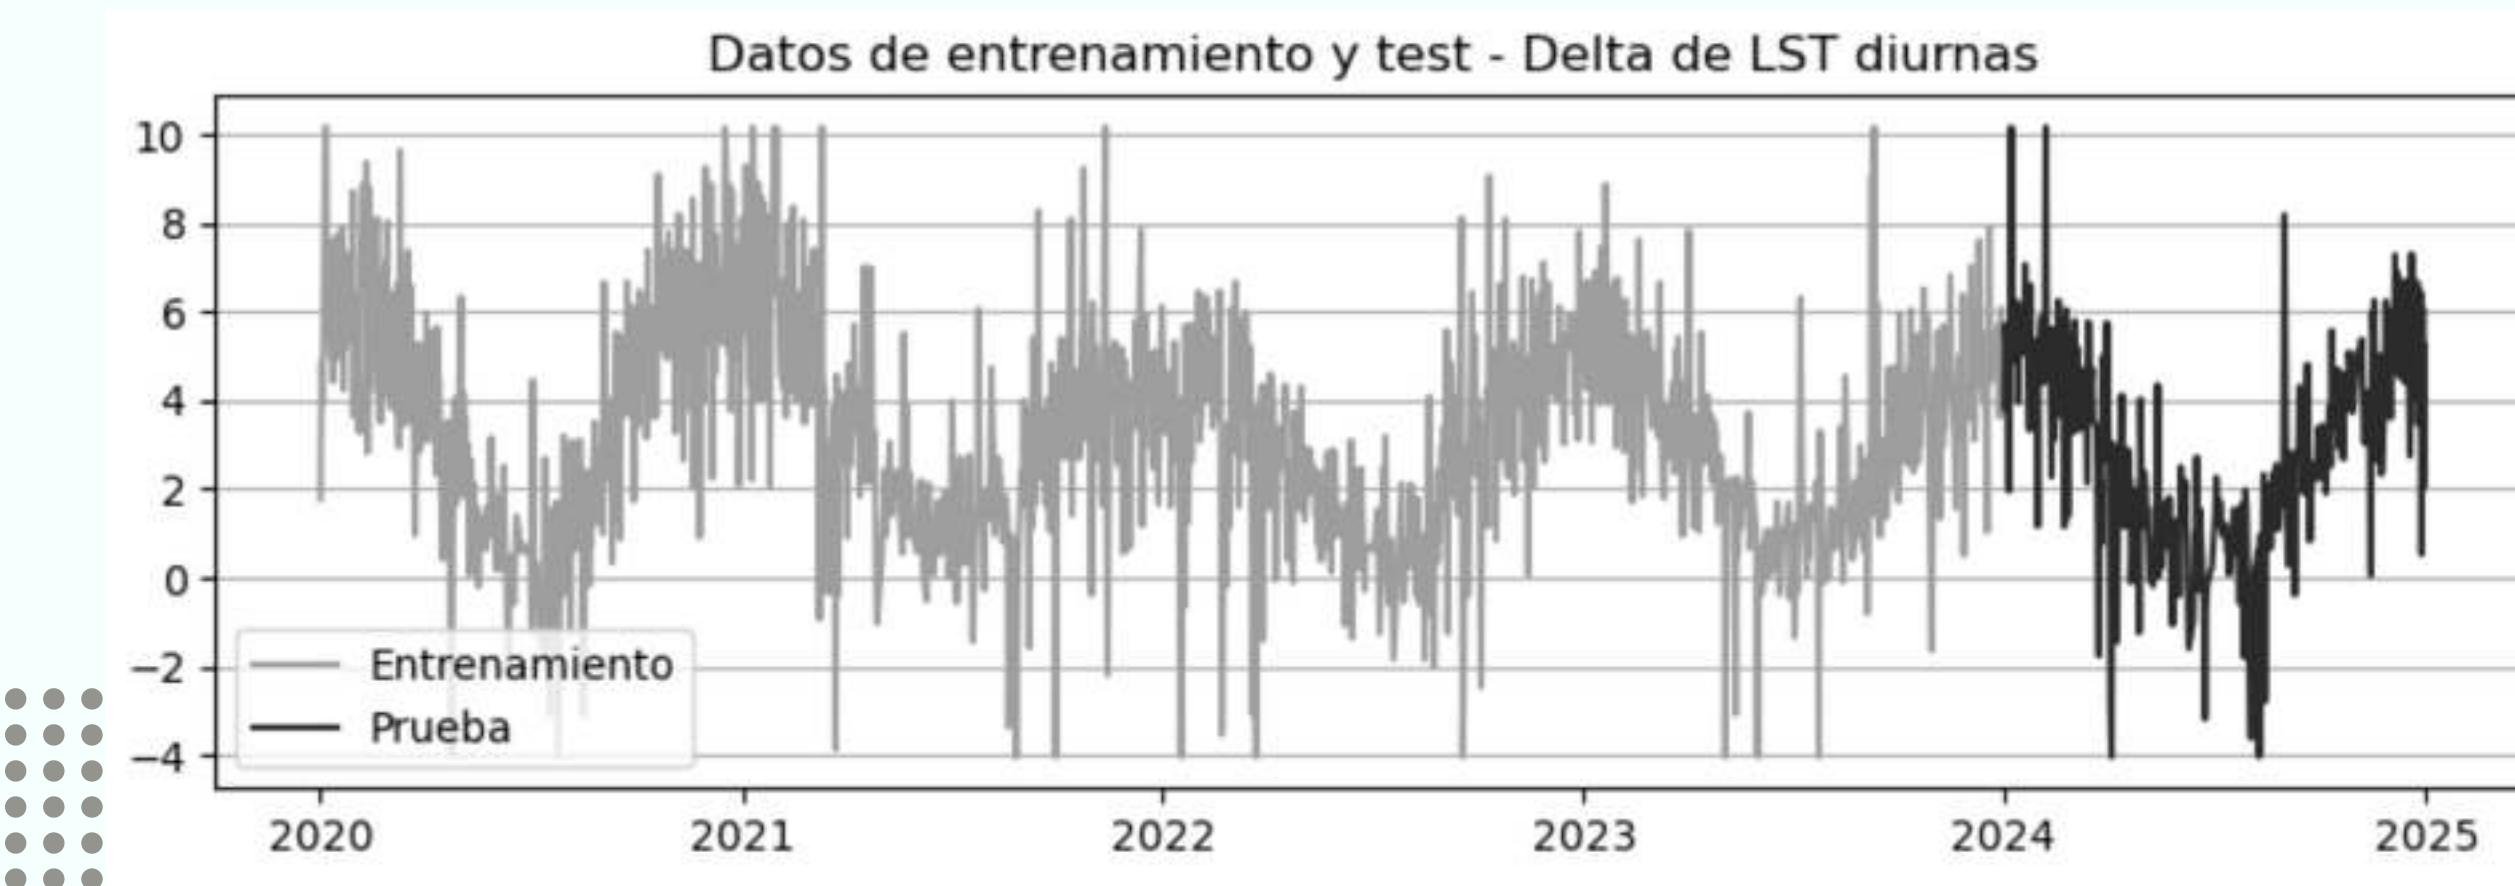
Entrenamiento

Train

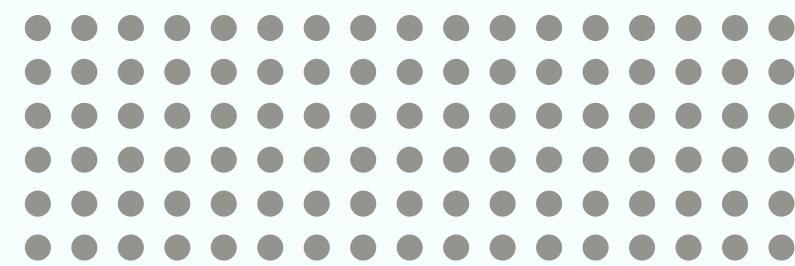
80 %

Test

20 %



Modelos predictivos

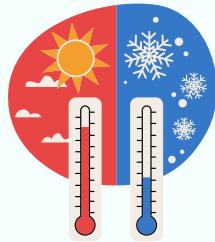


Holt-Winters (baseline)



Modelo ganador

Componente de tendencia aditiva + patrón de estacionalidad. Poco suavizado de amplitud. Suavizado medio de la tendencia y la estacionalidad. Phi alto (frena apenas la tendencia).



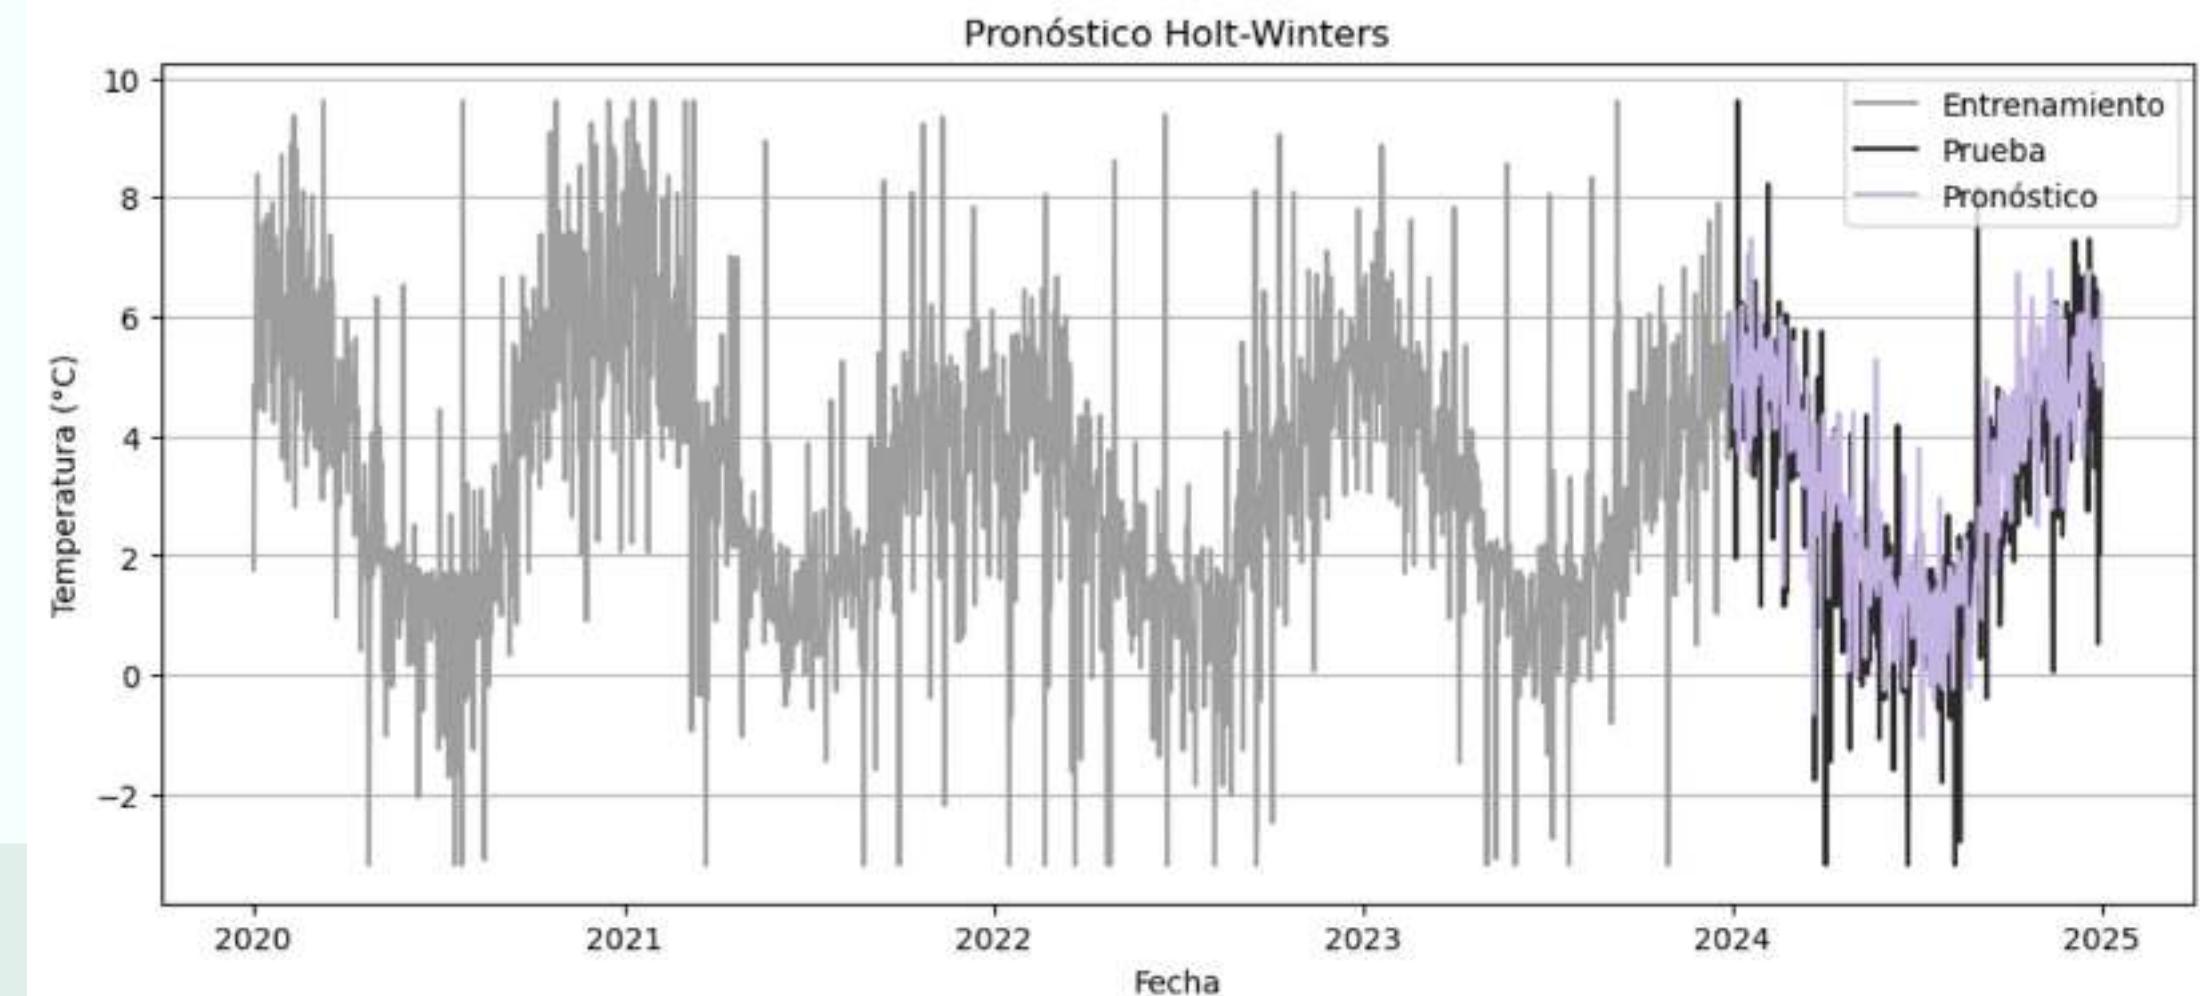
MAE 1.2660

MSE 2.9278

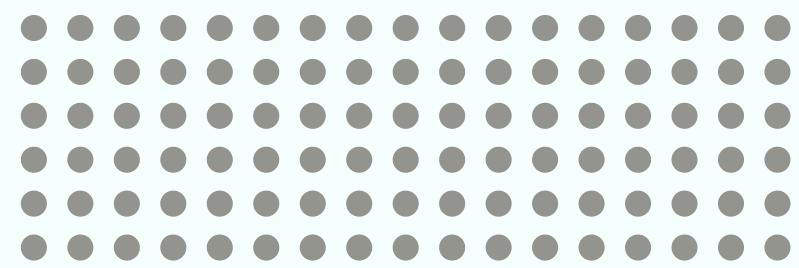
RMSE 1.7111

Entrenamiento

- Se probaron distintos niveles de suavizado, tendencia y componente estacional.
- seasonal_periods 365 (ciclo estacional anual).

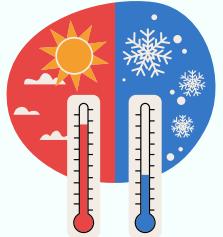


Modelos predictivos



Modelo ganador

1 capa + 0,3 dropout.



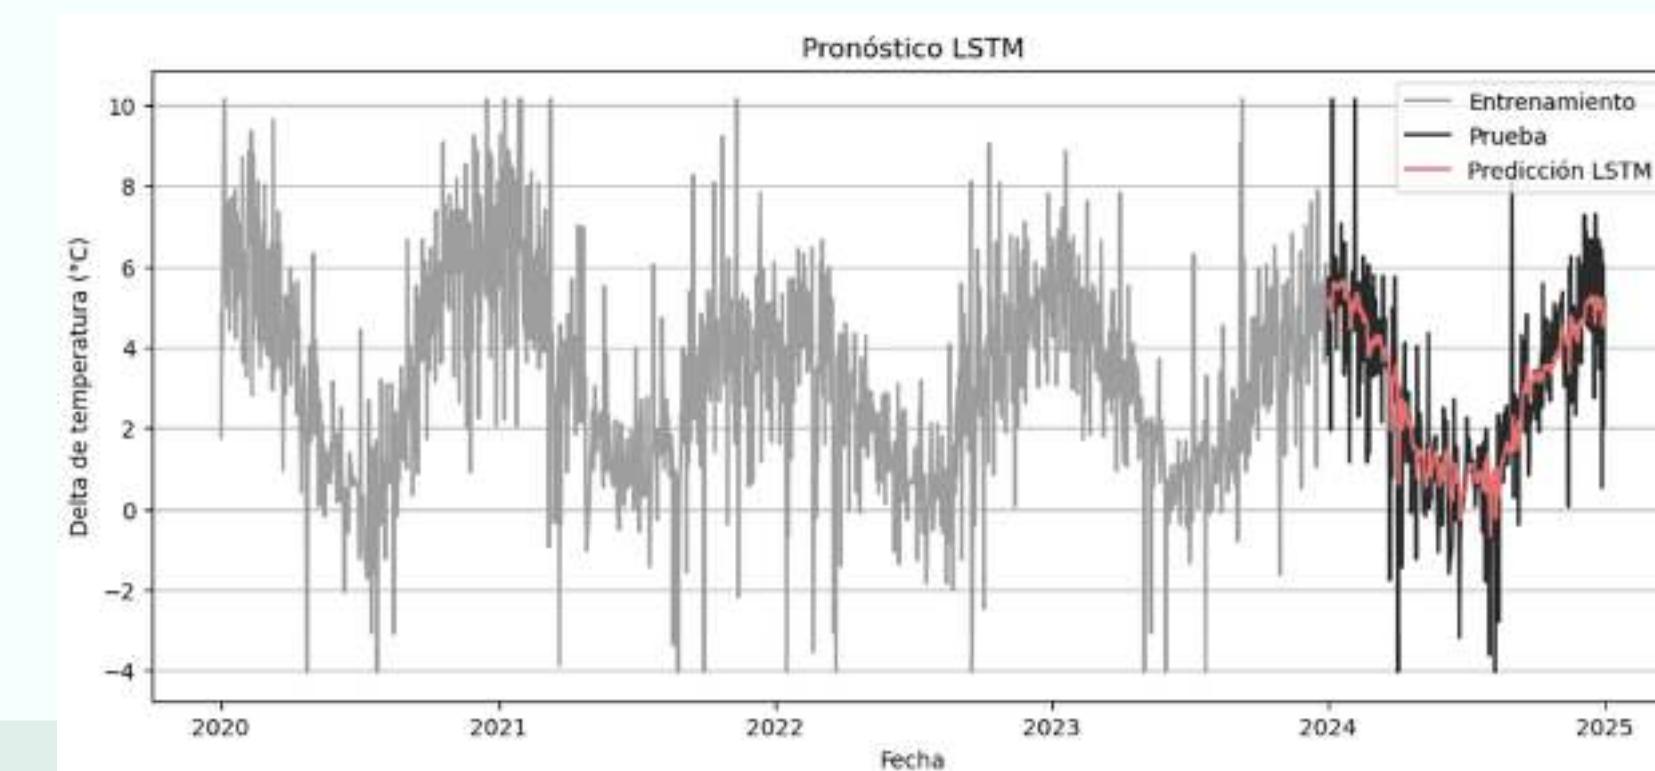
MAE	1.0049
MSE	1.9882
RMSE	1.4100

Arquitectura

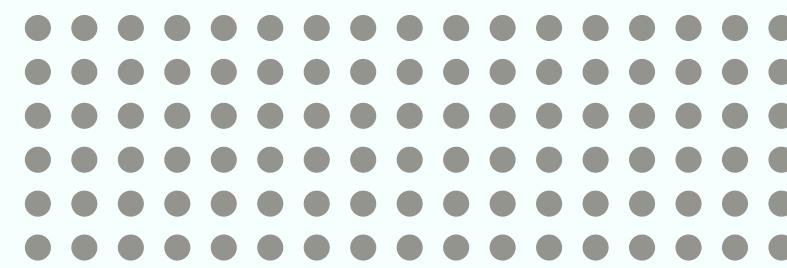
- Se probaron una y dos capas con activación tanh.
- Dropout para reducir el sobreajuste.
- Una capa densa que genera la predicción final.

Entrenamiento

- Optimizador Adam.
- Función de pérdida: mse.
- 100 épocas.
- Early stopping con una paciencia de 15 épocas.

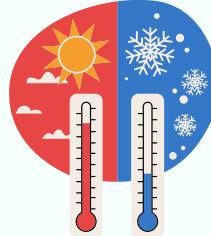


Modelos predictivos



Modelo ganador

1 capa + 0,4 dropout.



MAE 1.0048

MSE 1.9974

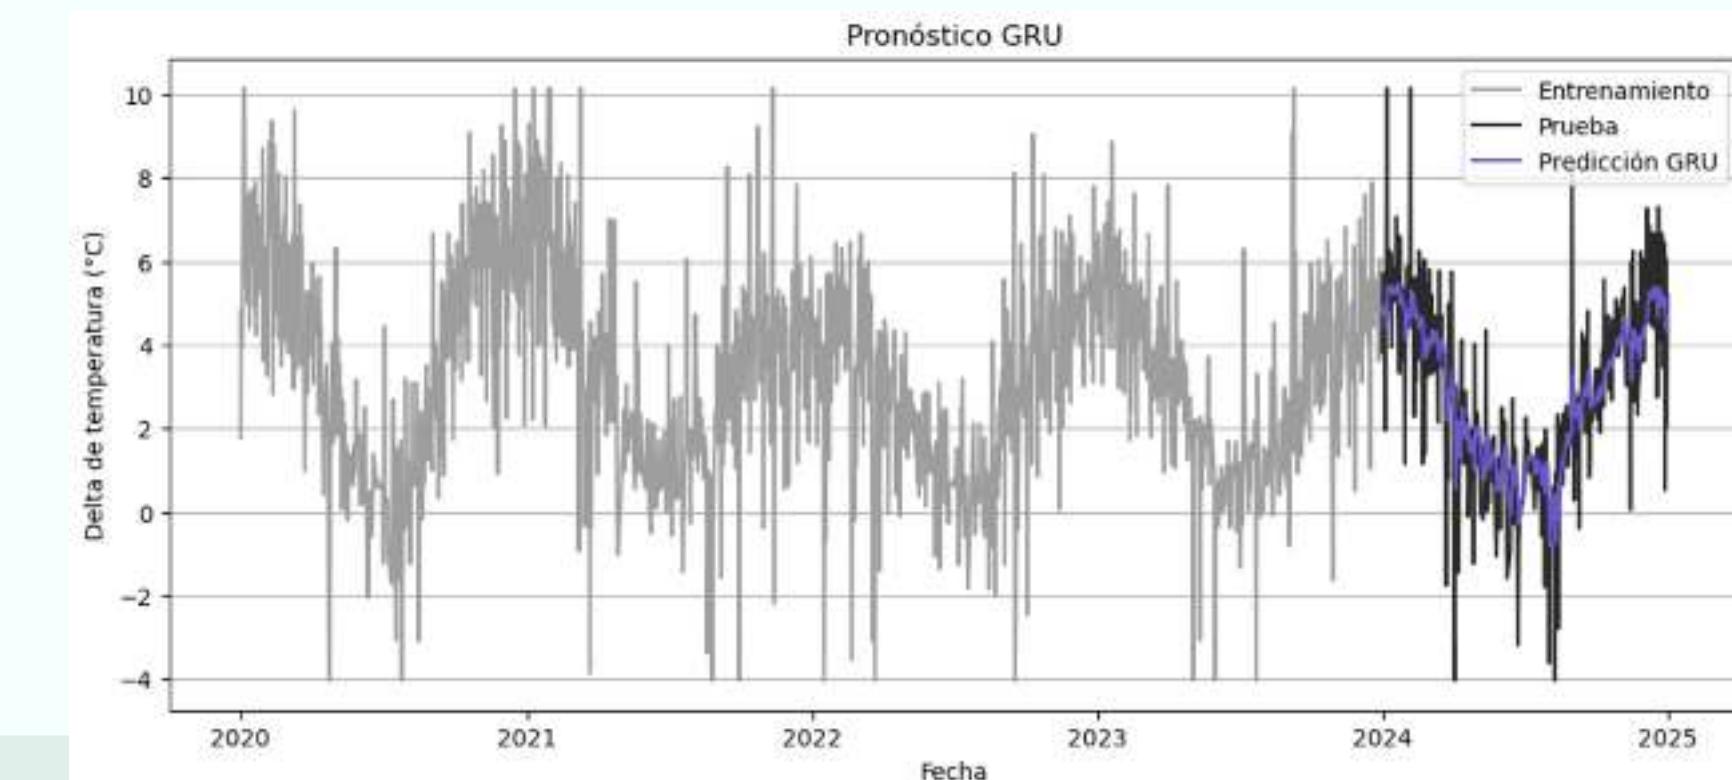
RMSE 1.4133

Arquitectura

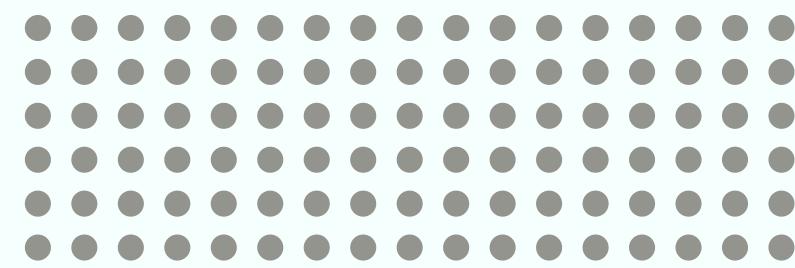
- Se probaron una y dos capas con activación tanh.
- Dropout para reducir el sobreajuste.
- Una capa densa que genera la predicción final.

Entrenamiento

- Optimizador Adam.
- Función de pérdida: mse.
- 100 épocas.
- Early stopping con una paciencia de 15 épocas.



Modelos predictivos

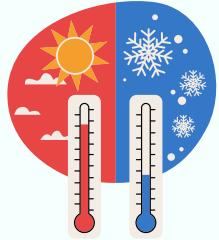


Transformer (Encoder-only)



Modelo ganador

3 layers, 4 heads de atención y Dropout de 0,15 y 0,4 .



MAE 1.402

MSE 3.287

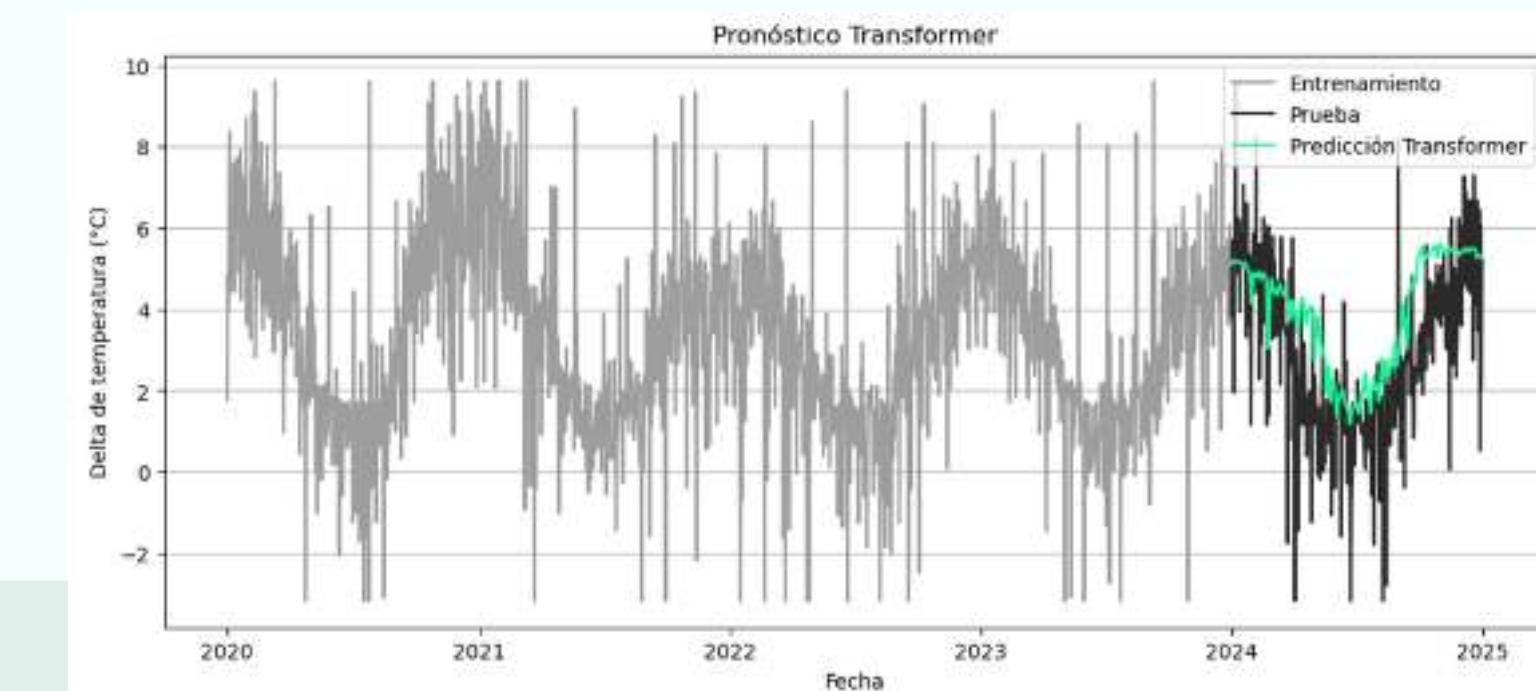
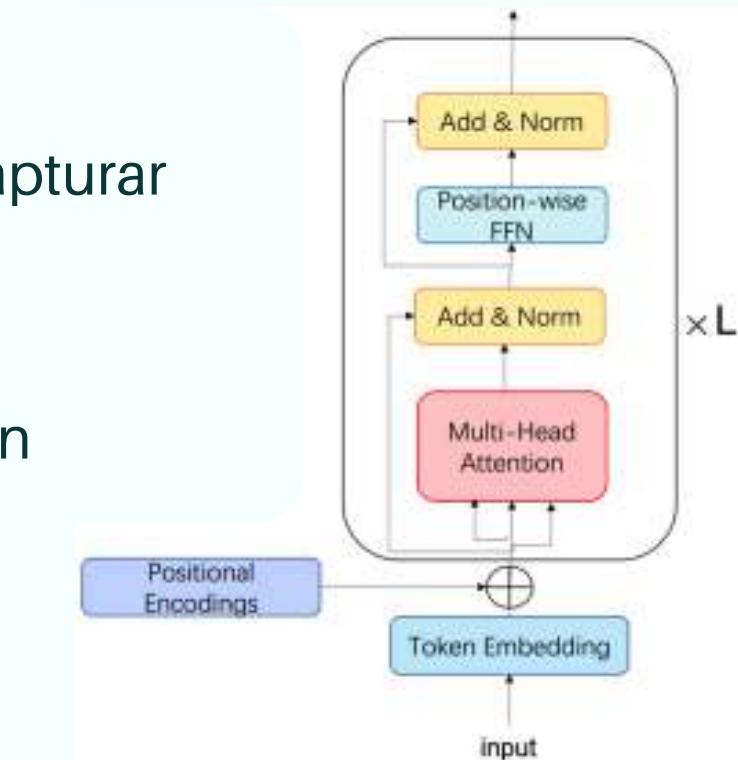
RMSE 1.813

Arquitectura

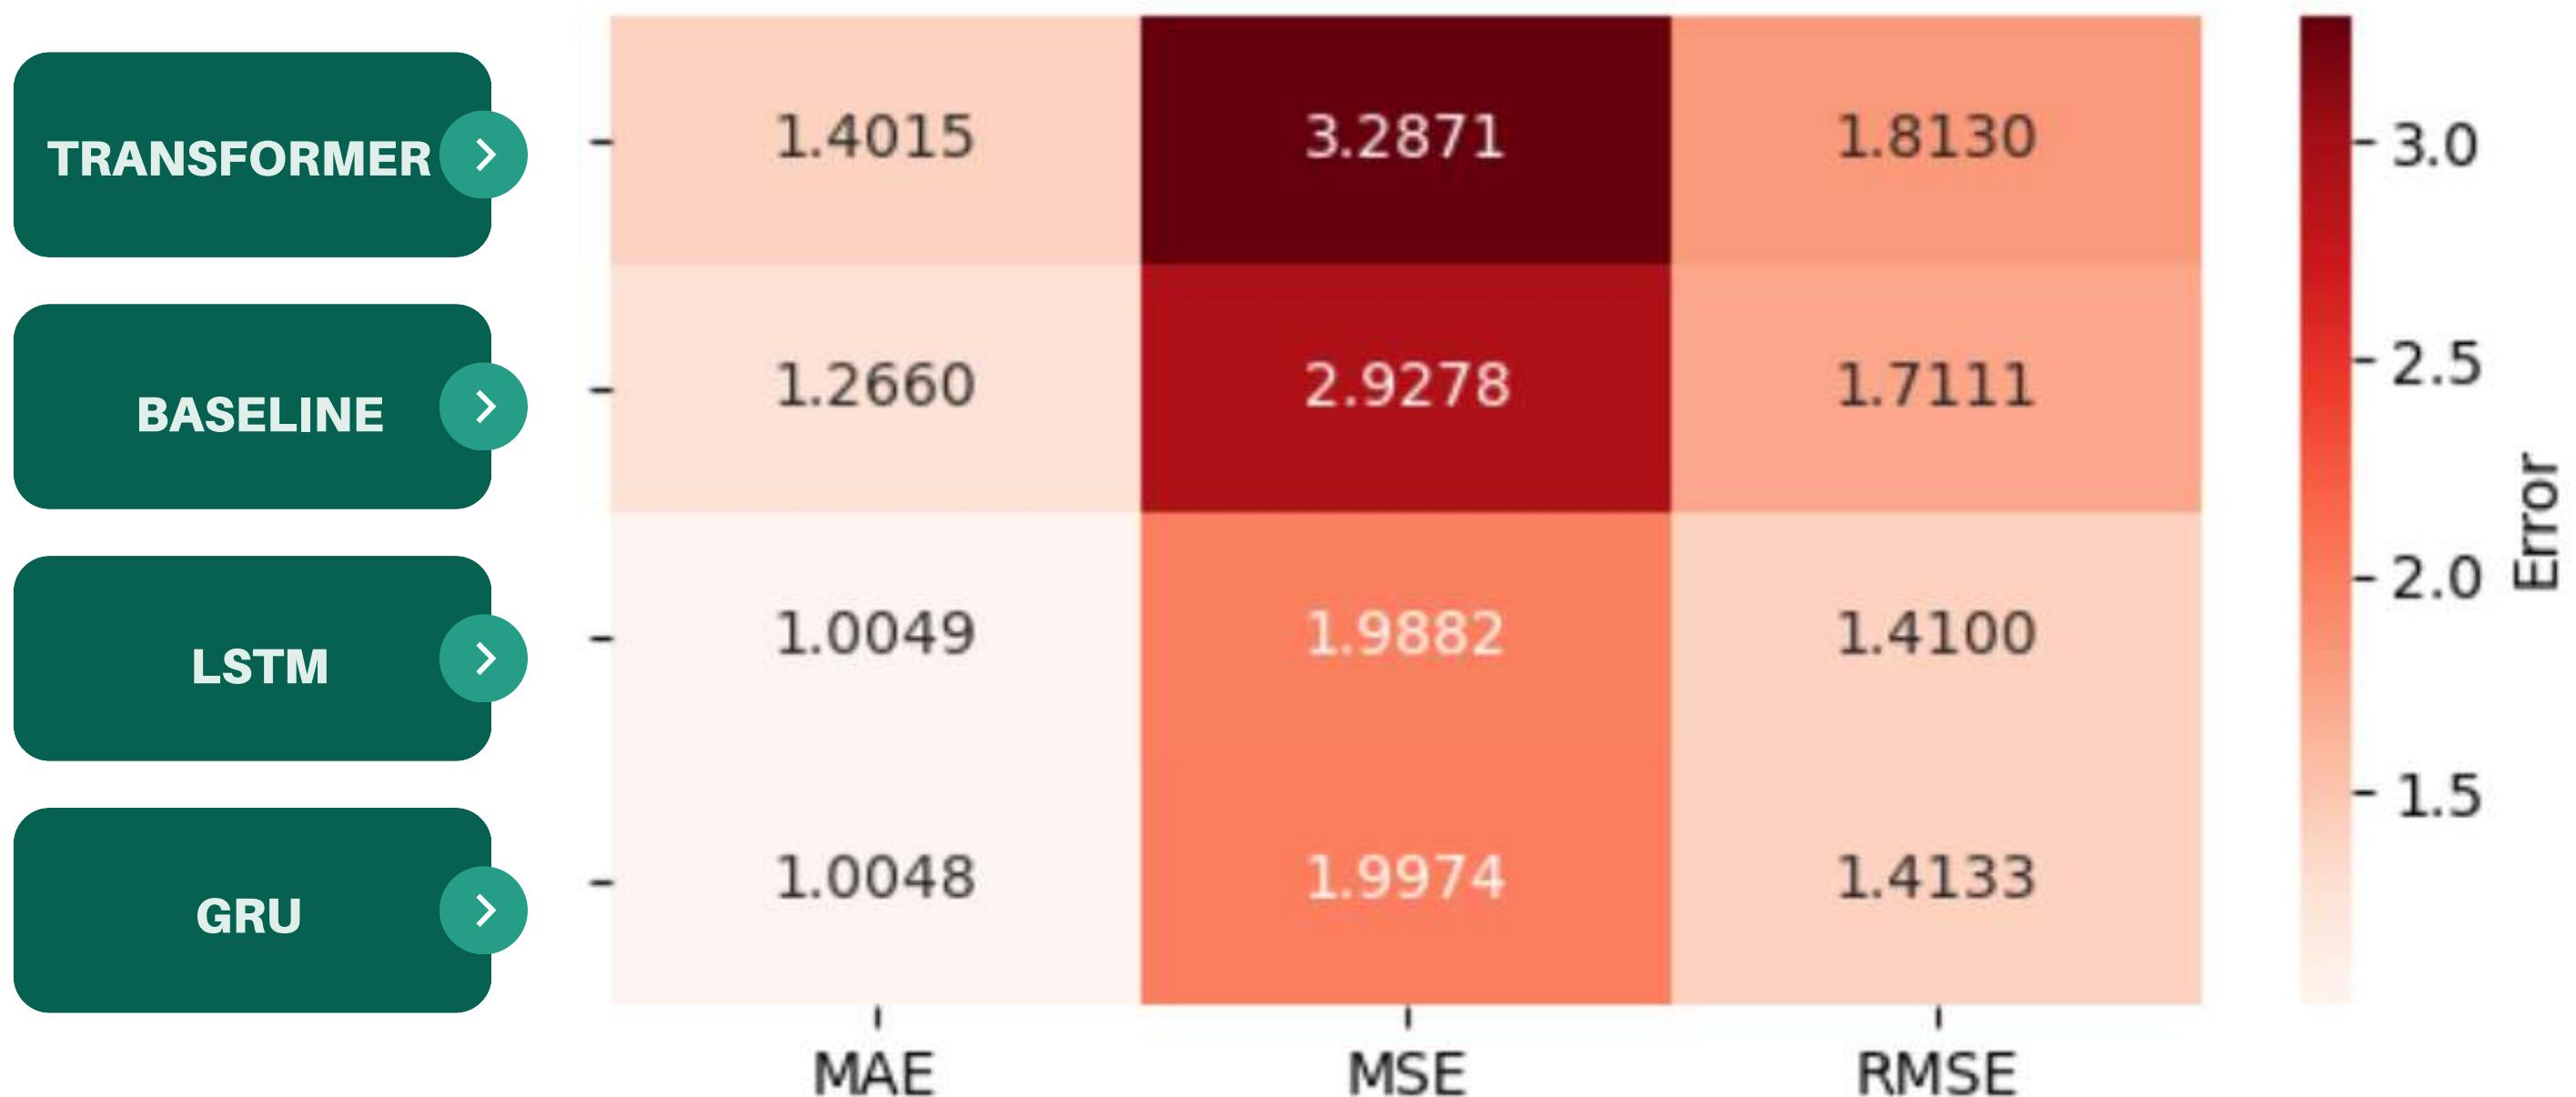
- Se utilizó encoder-only y multi-head self-attention para capturar dependencias temporales.
- Regularización con Dropout en múltiples etapas.
- Positional encoding sinusoidal para preservar información secuencial (ventana de 182 días).

Entrenamiento

- Optimizador Adam.
- Función de pérdida: mse.
- 100 épocas.
- Early stopping con una paciencia de 15 épocas.



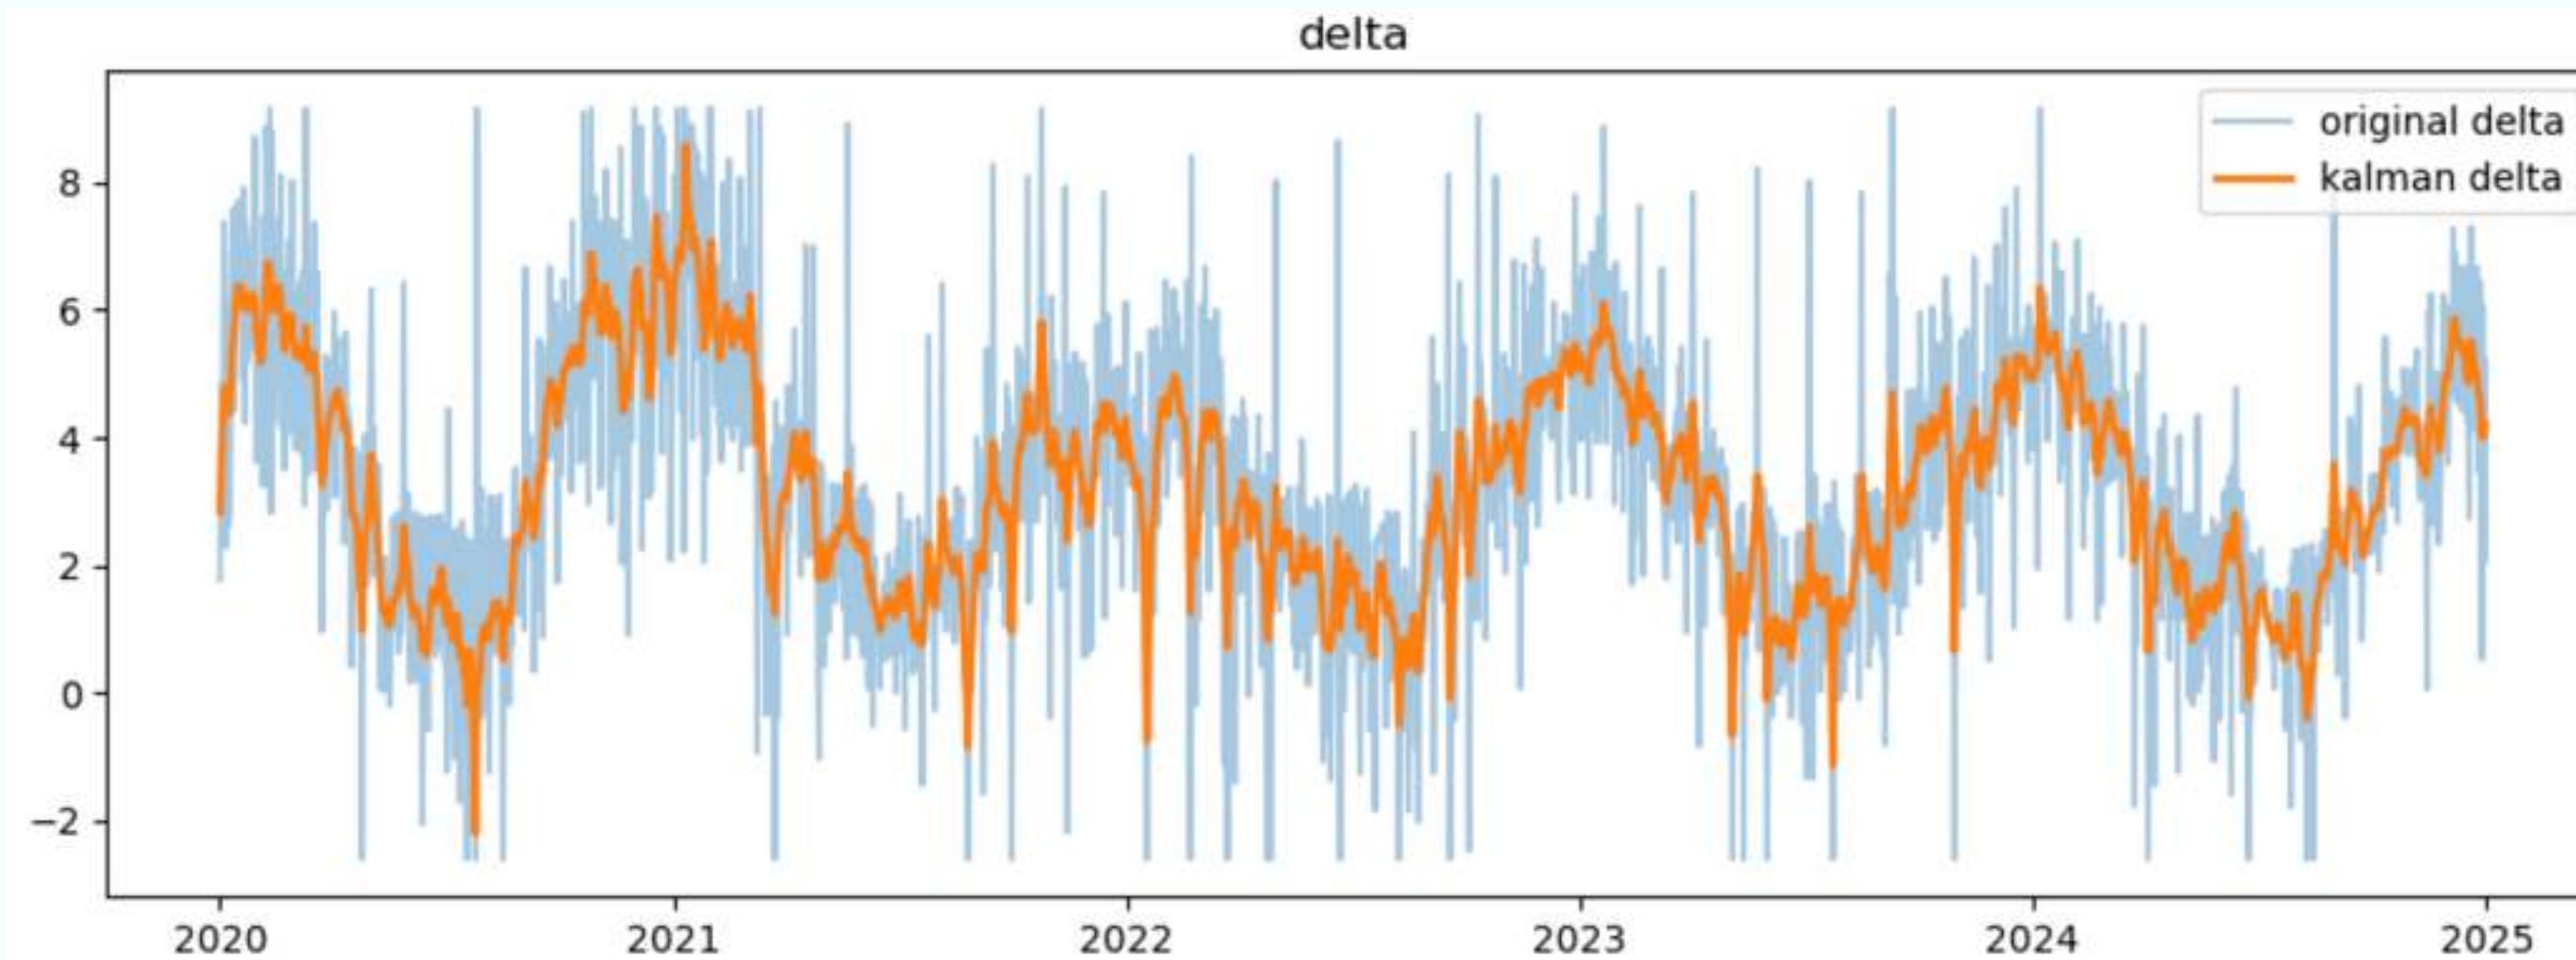
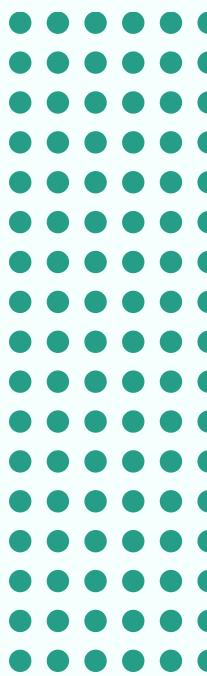
Resultados



Suavizado de la serie

Filtro de Kalman

Suaviza la serie calculando el valor 'verdadero' detrás de los datos ruidosos.

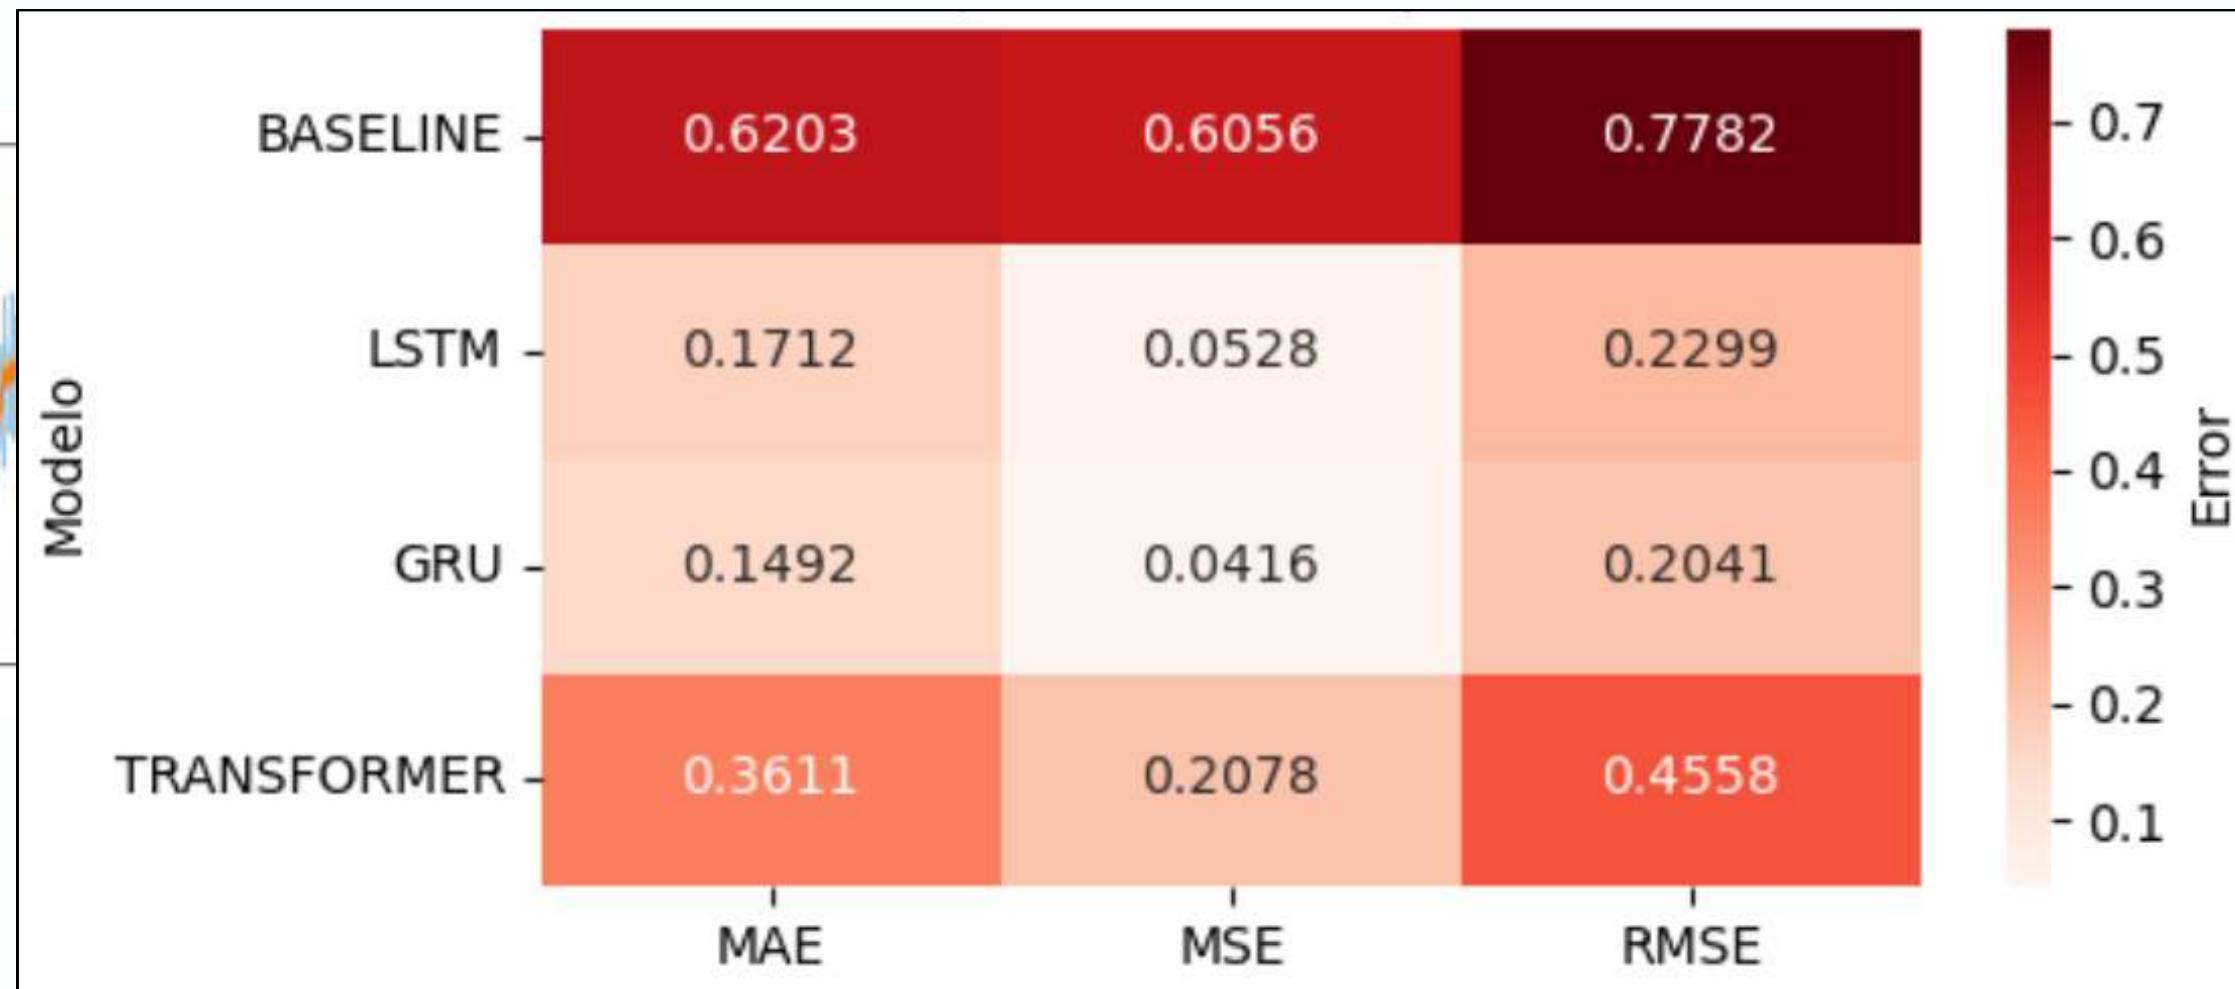
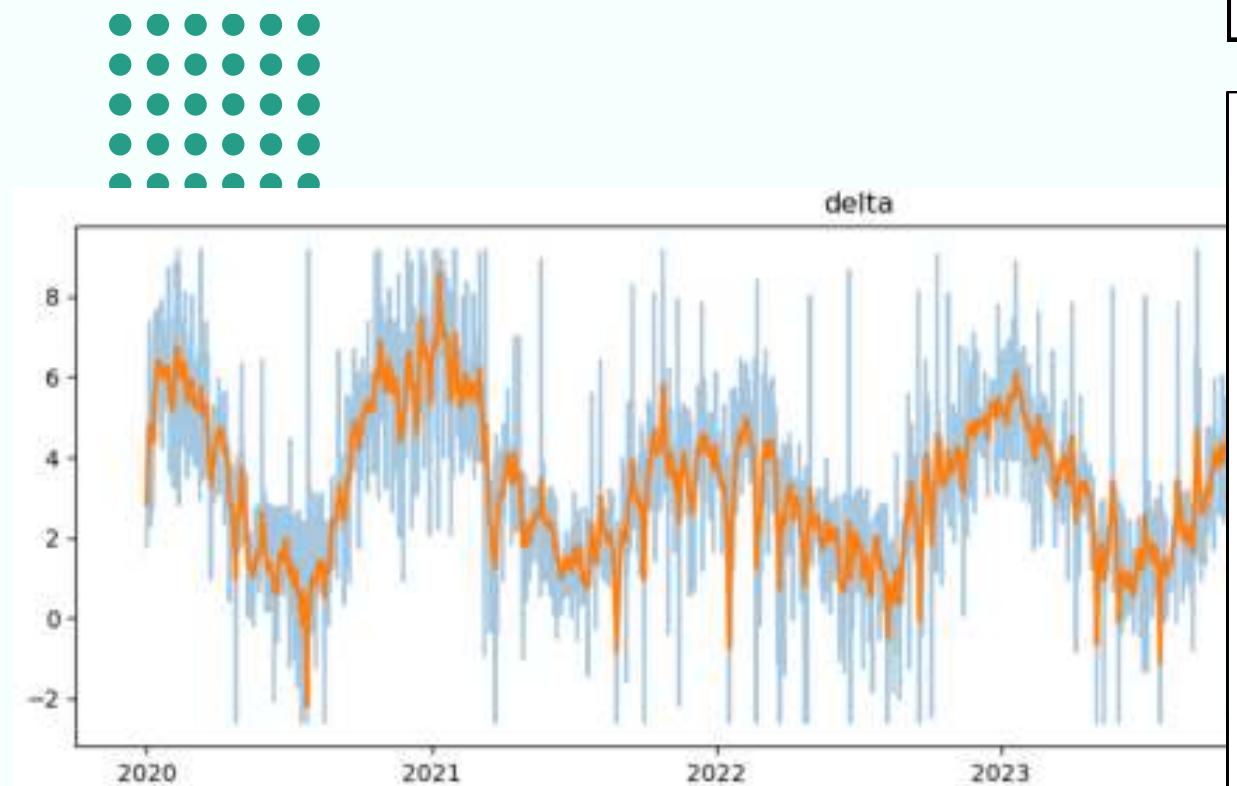


Suavizado de la serie

Filtro de Kalman

Suaviza la serie calculando el valor 'verdadero' detrás de los datos ruidosos.

- Reentrenamiento de los 4 modelos sobre la serie suavizada.

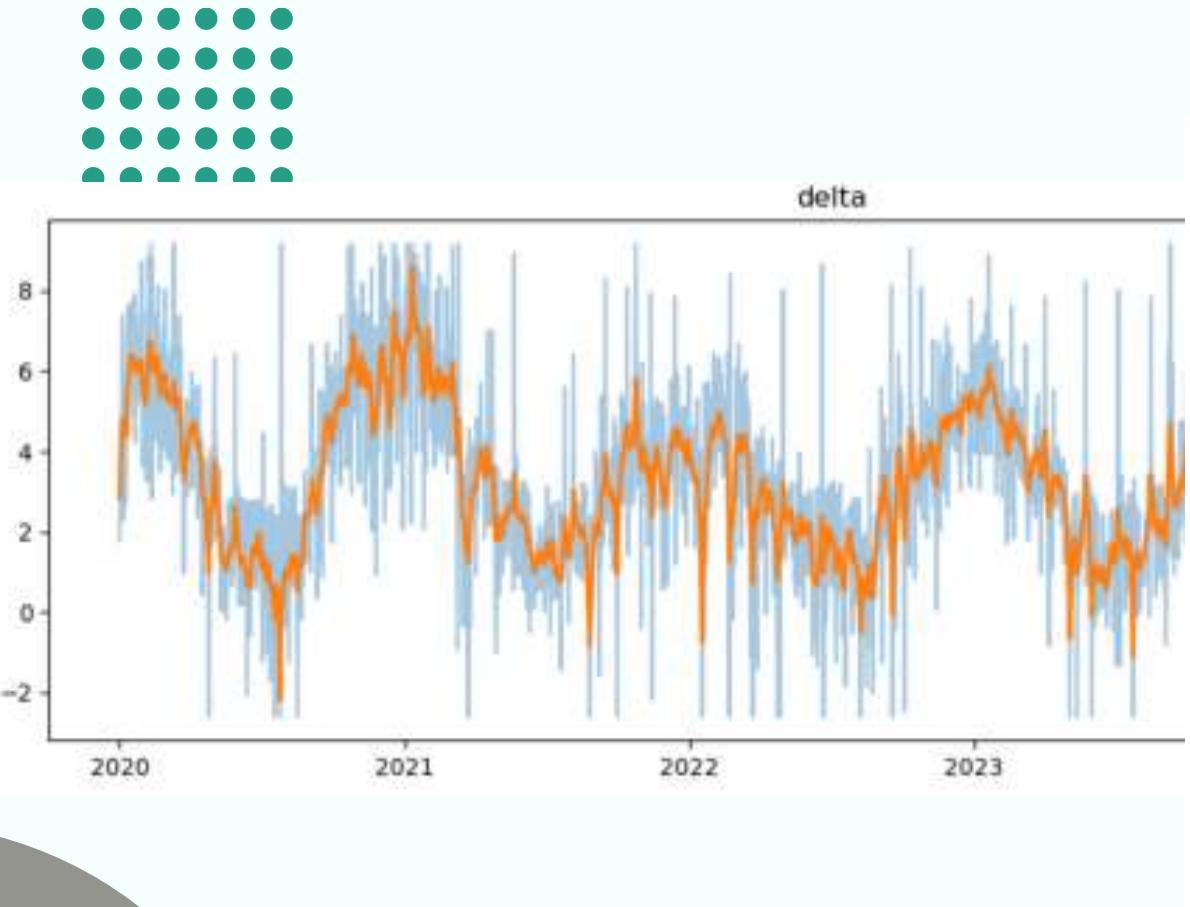


Suavizado de la serie

Filtro de Kalman

Suaviza la serie calculando el valor 'verdadero' detrás de los datos ruidosos.

- Mejora consistente en todas las métricas (MAE / MSE / RMSE).



Desafíos, dificultades y trabajo futuro



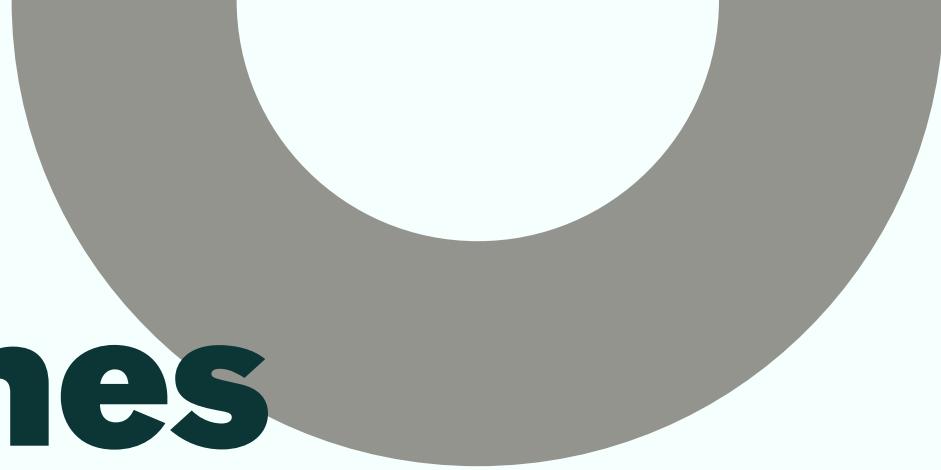
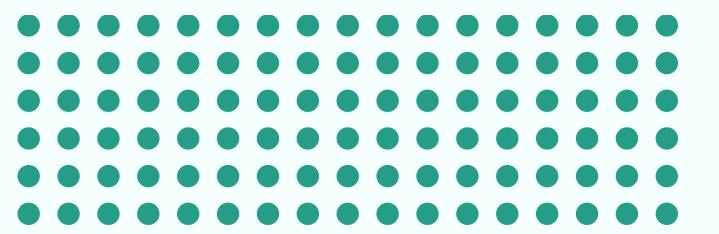
Desafíos y dificultades

- Mayores requerimientos computacionales.
- Tiempos de entrenamiento mucho más extensos (aún con pocos datos).
- Dificultades con la reproducibilidad.

Trabajo futuro

- Mejorar el rendimiento de los modelos:
 - más datos de entrenamiento.
 - mejorar la calidad de la serie de tiempo (suavizar, aplicar filtros en GEE, revisar la resolución espacial, etc.)
 - variables externas (humedad, albedo, etc.).





Conclusiones

- Utilizamos los modelos y herramientas vistas en la materia para imputar, filtrar, y hacer forecast de manera exitosa con pocos datos (3k aprox.).
- Arquitecturas como GRU, LSTM y Transformers capturan eficazmente la tendencia, la estacionalidad anual y la variabilidad de temperaturas diurnas.
- LSTM y GRU funcionaron mejor con arquitecturas pequeñas. Con el Transformer sucedió lo contrario (atención vs RNN).
- Las arquitecturas más complejas no se justifican para este caso de uso y se utilizaron solo con fines educativos.
- El filtro de Kalman suaviza la serie pero mantiene las variaciones distintivas originales. Su aplicación mejoró la capacidad para capturar la dinámica de la serie, y contribuyó a una mejora de 50-80 % aprox. en la performance de los modelos.

GRACIAS

